

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO
ĐỒ ÁN TỐT NGHIỆP
CẢI THIẾN MÔ HÌNH HỌC LIÊN TỤC
THÔNG QUA HỌC TƯƠNG PHẢN
NGÀNH: KHOA HỌC MÁY TÍNH

Hội đồng : 15L KHOA HỌC MÁY TÍNH

GVHD1 : PGS.TS. Lê Hồng Trang

GVHD2 : ThS. Dương Đức Tín

GVPB : TS. Huỳnh Văn Thống

SVTH : Nguyễn Quốc Tuấn - 2112585

TP. HỒ CHÍ MINH, THÁNG 5 NĂM 2026

Lời cam đoan

Em cam đoan rằng toàn bộ nội dung được trình bày trong báo cáo đồ án tốt nghiệp này là tự viết hoàn toàn. Các thông tin được sử dụng từ các nguồn khác đều được ghi rõ nguồn, trích dẫn theo quy định của trường Đại học Bách Khoa - Đại học Quốc gia TP.HCM.

Em cam đoan tuân thủ các quy định và tiêu chuẩn trong quá trình nghiên cứu và trình bày kết quả nghiên cứu đồ án tốt nghiệp này. Nếu phát hiện ra bất kỳ sự vi phạm lời cam đoan này, em xin chịu hoàn toàn trách nhiệm.

Nguyễn Quốc Tuấn

Lời cảm ơn

Đầu tiên, em xin gửi lòng biết ơn sâu sắc đến Trường Đại học Bách khoa - Đại học Quốc gia TP.HCM và Khoa Khoa học và Kỹ thuật Máy tính. Những bài học, kiến thức và kỹ năng mà các giảng viên đã dạy bảo là tài sản vô giá trong hành trình phát triển của em.

Tiếp sau đó, em xin gửi lời cảm ơn chân thành đến thầy Lê Hồng Trang và thầy Dương Đức Tín. Hai thầy đã tận tình hướng dẫn, chỉ bảo và đưa ra những ý kiến quý báu giúp em hoàn thành đồ án này.

Cuối cùng, một lời cảm ơn đặc biệt gửi đến bản thân đã cố gắng hết sức, tìm tòi học hỏi và hoàn thiện đồ án này.

Nguyễn Quốc Tuấn

Tóm tắt

Trong kỷ nguyên số hóa, các hệ thống thị giác máy tính như drone viễn thám, xe tự lái, robot phục vụ hay camera giám sát an ninh đang phải hoạt động trong một môi trường thế giới thực biến động không ngừng. Thay vì chỉ xử lý một tập dữ liệu cố định, các hệ thống này liên tục tiếp nhận luồng dữ liệu mới theo thời gian thực, với các điều kiện mới (các vật thể, điều kiện ánh sáng, bối cảnh mới...) chưa từng được huấn luyện trước đó. Thực tiễn tạo ra thách thức buộc AI phải có khả năng "học liên tục" - cập nhật tri thức mới ngay lập tức mà không tốn thời gian học lại toàn bộ mô hình từ con số không.

Tuy nhiên, trở ngại lớn nhất khi hiện thực và áp dụng học liên tục là hiện tượng "quên thảm khốc" - hiện tượng mô hình quên sạch kiến thức cũ trong quá trình học kiến thức mới. Hậu quả là mô hình có kết quả rất tốt với tác vụ vừa học, nhưng lại mất đi hiệu suất tương tự cho những tác vụ cũ.

Đã có nhiều nghiên cứu để giải quyết vấn đề đó. Đề tài này tái hiện lại một kiến trúc học liên tục, nghiên cứu và áp dụng vào đó phương pháp "học tương phản" - một cách tiếp cận dựa trên việc học biểu diễn tính tương quan giữa các nhiệm vụ - đồng thời kết hợp một bộ nhớ đệm nhỏ. Giải pháp này được mong đợi cải thiện việc học liên tục, bằng cách xây dựng một không gian đặc trưng tách biệt các lớp dữ liệu dựa vào mối tương quan lấy các dữ liệu cũ làm nền tảng. Nhờ đó, AI có thể tích lũy kiến thức theo thời gian mà không đánh mất quá nhiều những gì đã học.

Mục lục

1	Giới thiệu đề tài	8
1.1	Tổng quan	8
1.2	Nhiệm vụ đề tài	9
1.3	Đóng góp chính	10
1.4	Cấu trúc báo cáo	10
2	Các nghiên cứu liên quan	11
2.1	Trích xuất đặc trưng hình ảnh với kiến trúc ResNet	11
2.1.1	Vấn đề thoái hóa trong quá trình huấn luyện mạng neuron sâu	11
2.1.2	Cơ chế Học phần dư	12
2.1.3	Cấu trúc khối xây dựng cơ bản	13
2.1.4	Quá trình học đặc trưng phân cấp	14
2.2	Học liên tục	14
2.2.1	Mâu thuẫn nội tại	15
2.2.2	Các phương pháp tiếp cận trong học liên tục	15
2.2.3	Các kịch bản thiết lập bài toán trong Học liên tục	20
2.2.4	Các chỉ số đánh giá học liên tục	22
2.3	Học biểu diễn Tương phản	22
2.3.1	Nguyên lý cơ bản	22
2.3.2	Khung xử lý chính	23
2.3.3	Cơ chế hoạt động của Gradient và vai trò của Nhiệt độ τ	25
2.3.4	Phân tích đặc tính hình học	26
2.4	Baseline Co ² L và động lực của SMC ² L	27
2.4.1	Co ² L: Học liên tục dựa trên tương phản	27
2.4.2	Ưu nhược điểm của Co ² L	29
2.4.3	Động lực của SMC ² L	30
3	Phương pháp đề xuất - SMC²L	32
3.1	Tổng quan kiến trúc	32
3.2	Xây dựng Batch không nhãn với LUMP Mixup	33
3.2.1	Loại bỏ chiều nhãn	33
3.2.2	Nội suy giữa tác vụ hiện tại và buffer	33

3.2.3	Tăng cường hai view và batch làm giàu	34
3.3	Hàm mất mát tổng hợp của SMC ² L	34
3.3.1	Hàm mất mát Tương phản	35
3.3.2	Hàm mất mát Chứng cất quan hệ	36
3.3.3	Siêu tham số λ	37
3.4	Kiến trúc triển khai SMC ² L	37
3.4.1	Khối Tiền xử lý	37
3.4.2	Khối Mã hóa	38
3.4.3	Khối huấn luyện chính	40
4	Thực nghiệm	41
4.1	Thiết lập thực nghiệm	41
4.1.1	Tập dữ liệu và kịch bản	41
4.1.2	Kiến trúc mô hình học sâu	41
4.1.3	Tăng cường dữ liệu	41
4.1.4	Optimizer và Scheduler	42
4.1.5	Siêu tham số	42
4.2	Quy trình đánh giá	42
4.3	Kết quả thực nghiệm	43
4.3.1	Kết quả chính	43
4.3.2	Thực nghiệm trên tập dữ liệu ảnh vệ tinh	44
4.4	Nghiên cứu Ablation	44
5	Tổng kết	46
5.1	Đánh giá thực nghiệm	46
5.1.1	Về hiệu quả tổng thể	46
5.1.2	Về hạn chế	47
5.2	Hướng phát triển	47
5.2.1	Cải tiến chiến lược lấy mẫu Buffer	47
5.2.2	Siêu tham số động trong quá trình huấn luyện	48
5.3	Kết luận	48

Danh sách hình vẽ

2.1	Các phương pháp học liên tục [1].	16
3.1	Tổng quan kiến trúc. Nhãn bị loại bỏ ở giai đoạn huấn luyện. Mẫu tác vụ hiện tại và mẫu buffer được kết hợp qua LUMP mixup, sau đó tăng cường thành hai view đưa vào encoder hiện tại để tính $\mathcal{L}_{mix}^{con}$. Mẫu buffer được dẫn qua cả encoder hiện tại và encoder đóng băng để tính $\mathcal{L}_{buf}^{IRD}$; sg là stop-gradient trên encoder cũ.	32
3.2	Các biến đổi ngẫu nhiên [2].	38
3.3	Các lớp Resnet-18 [3].	39

Danh sách bảng

2.1	So sánh các phương pháp liên quan theo các tiêu chí: học tự giám sát (không cần nhãn), học tương phản, hỗ trợ học liên tục đa tác vụ.	31
4.1	Không gian tìm kiếm siêu tham số.	42
4.2	Độ chính xác phân loại (%) trên Seq-CIFAR-10, Seq-Tiny-ImageNet và R-MNIST với buffer size 500. Kết quả của các phương pháp lấy từ [4]. Kết quả tốt nhất in đậm . Kết quả SMC ² L lấy trung bình trên 5 lần chạy độc lập.	43
4.3	Kết quả trên EuroSAT, buffer size 500. Đơn vị: %.	44
4.4	Nghiên cứu ablation các kết quả accuracy tốt nhất trên Seq-CIFAR-10, buffer size 500. Đơn vị: %.	45

Chương 1

Giới thiệu đề tài

1.1 Tổng quan

Trong các hệ thống thông minh, đặc biệt là các ứng dụng triển khai phương tiện không người lái và nền tảng hàng không vũ trụ, bài toán nhận dạng đối tượng đặt ra nhiều thách thức do đặc tính động của môi trường hoạt động. Khi các hệ thống này xử lý lượng dữ liệu ngày càng lớn, các lớp đối tượng chưa từng thấy sẽ liên tục xuất hiện theo thời gian. Mô hình nhận dạng trên thiết bị phải học liên tục các lớp mới này mà không quên các lớp đã học trước đó, đây chính là bài toán cốt lõi của học liên tục. Mô hình học máy phải học tuần tự theo thời gian. Một thách thức trọng tâm trong bối cảnh này là hiện tượng "quên thảm khốc" [5, 6], tức là xu hướng của mạng neuron ghi đè kiến thức cũ khi học các tác vụ mới. Để giảm thiểu vấn đề này, học liên tục tìm cách cân bằng giữa tính linh hoạt (khả năng học thông tin mới) và tính ổn định (khả năng duy trì kiến thức đã học).

Thêm vào đó, dữ liệu thu thập từ các nền tảng trên không đến với tốc độ cao và trong điều kiện khó dự đoán, khiến việc gán nhãn thủ công trở nên tốn kém và thường không khả thi. Điều này làm hạn chế nghiêm trọng các phương pháp học liên tục có giám sát hoàn toàn trong thực tế và thúc đẩy sự quan tâm đến học liên tục tự giám sát, nghĩa là học các đặc trưng biểu diễn trực tiếp từ dữ liệu không có nhãn [7, 4].

Để giải quyết cả hai thách thức trên, và tiếp nối kết quả sơ khởi của đề tài giai đoạn 1, đề tài giai đoạn 2 đề xuất khung học liên tục tự giám sát **SMC²L** (Self-Supervised Mixup Contrastive Continual Learning). Trong bối cảnh dữ liệu từ các nền tảng trên không đến liên tục, tốc độ cao và không có nhãn, việc xây dựng một hệ thống học liên tục *không phụ thuộc vào nhãn ngay từ thiết kế kiến trúc*, thay vì coi đó là một ràng buộc phụ, là hướng tiếp cận phù hợp hơn về mặt thực tiễn. Các đặc trưng học được mà không bị ràng buộc bởi ranh giới lớp cụ thể có xu hướng tổng quát hơn, bền vững hơn trước sự thay đổi phân phối, và dễ tái sử dụng xuyên suốt chuỗi tác vụ liên tục, đây chính là lợi thế cốt lõi mà học tự giám sát mang lại trong bối cảnh học liên tục.

SMC²L được xây dựng trên nền tảng Co²L [4] với ba đóng góp kỹ thuật chính: (1) định nghĩa lại mục tiêu học biểu diễn theo hướng hoàn toàn tự giám sát thông qua SimCLR [2], loại bỏ sự phụ thuộc vào nhãn lớp ở mọi bước trong giai đoạn học đặc trưng; (2) đề xuất vận dụng cơ chế nội suy LUMP mixup [8, 7] vào chung với hàm mất mát tương phản để tạo cầu nối liên tục giữa phân phối tác vụ hiện tại và tác vụ cũ ngay ở cấp độ đầu vào, giải quyết hiện tượng dịch chuyển biểu diễn đột ngột tại ranh giới tác vụ mà các phương pháp tự giám sát liên tục thuần túy thường gặp; và (3) thiết kế lại phạm vi áp dụng của chứng cất quan hệ theo mẫu (IRD) [4], giới hạn chỉ trên các mẫu trong bộ nhớ đệm để loại bỏ nhiễu gradient từ dữ liệu tác vụ hiện tại mà mô hình cũ chưa từng thấy, biến IRD từ một nguồn nhiễu tiềm ẩn thành tín hiệu bảo toàn tri thức tập trung và hiệu quả.

1.2 Nhiệm vụ đề tài

Đề án tốt nghiệp là sự tiếp nối trực tiếp của giai đoạn nghiên cứu đề án chuyên ngành, trong đó chúng tôi đã khảo sát nền tảng lý thuyết, đề xuất sơ khởi và thực nghiệm ban đầu về học liên tục dựa trên học tương phản. Cụ thể, giai đoạn 1 đã hoàn thành các nhiệm vụ:

- Tìm hiểu các mô hình học liên tục và các ứng dụng điển hình.
- Tìm hiểu các kỹ thuật đã đề xuất cho các mô hình học liên tục và kết quả mới nhất hiện nay.
- Tìm hiểu các kỹ thuật học tương phản và tính chất đặc trưng của các mô hình này.
- Nghiên cứu và đề xuất sơ khởi một mô hình học liên tục sử dụng học tương phản.
- Hiện thực và thực nghiệm sơ khởi. Đánh giá kết quả thu được.

Kế thừa nền tảng đó, giai đoạn 2 tập trung hoàn thiện và cải thiện với các nhiệm vụ cụ thể hơn:

- Tìm hiểu các mô hình học liên tục và các ứng dụng điển hình, đặc biệt trong bối cảnh các hệ thống Drone viễn thám không dùng nhãn.
- Tìm hiểu các kỹ thuật đã đề xuất cho các mô hình học liên tục và kết quả mới nhất hiện nay.
- Tìm hiểu các kỹ thuật học tương phản tự giám sát và tính chất đặc trưng của các mô hình này.
- Nghiên cứu cơ chế mixup trong học biểu diễn liên tục để giảm thiểu sự dịch chuyển đặc trưng đột ngột tại ranh giới tác vụ.
- Đề xuất và cài đặt khung SMC²L kết hợp SimCLR, LUMP mixup và IRD buffer-only.
- Thực nghiệm trên các tập dữ liệu chuẩn: Seq-CIFAR-10, Seq-Tiny-ImageNet, R-MNIST.
- Đánh giá kết quả và so sánh với các baseline có giám sát và tự giám sát.

1.3 Đóng góp chính

Các đóng góp chính của đề tài bao gồm:

- Đề xuất khung học liên tục hoàn toàn tự giám sát không cần nhãn trong giai đoạn học biểu diễn, trong khi vẫn duy trì chất lượng biểu diễn tương đương hoặc tốt hơn các phương pháp dựa trên tương phản trước đó.
- Giới thiệu hàm mất mát tương phản kết hợp LUMP mixup làm mượt không gian biểu diễn tại ranh giới tác vụ, giúp giảm sự dịch chuyển đặc trưng đột ngột mà các phương pháp tự giám sát liên tục thường gặp.
- Thực nghiệm trên các benchmark chuẩn của học liên tục (Seq-CIFAR-10, Seq-Tiny-ImageNet, R-MNIST) và cho thấy kết quả cạnh tranh so với cả baseline có giám sát và tự giám sát trong kịch bản học tăng cường lớp (Class-Incremental Learning).

Source code và quá trình chạy thực nghiệm của đề tài có thể xem tại đây: <https://github.com/tuan2k33/HK252-DATN-024/>

1.4 Cấu trúc báo cáo

Ngoài danh sách hình vẽ, danh sách bảng và tài liệu tham khảo, báo cáo được chia thành 5 chương:

- **Chương 1. Giới thiệu đề tài.** Chương cung cấp cái nhìn bao quát, động lực từ ứng dụng thực tế, nhiệm vụ và các đóng góp chính của đề tài.
- **Chương 2. Các nghiên cứu liên quan.** Chương trình bày cơ sở lý thuyết về trích xuất đặc trưng với ResNet, học liên tục, học biểu diễn tương phản (SimCLR, SupCon, Co²L) và các hướng nghiên cứu tự giám sát liên tục.
- **Chương 3. Phương pháp đề xuất.** Chương mô tả chi tiết kiến trúc SMC²L: xây dựng batch không nhãn với LUMP mixup, hàm mất mát tương phản tự giám sát, hàm mất mát chưng cất và quy trình huấn luyện tổng thể.
- **Chương 4. Thực nghiệm.** Chương trình bày thiết lập thực nghiệm, kết quả so sánh trên ba tập dữ liệu và nghiên cứu ablation các thành phần.
- **Chương 5. Tổng kết.** Chương tóm gọn và đánh giá kết quả thực nghiệm, phân tích hạn chế và đề ra các hướng phát triển.

Chương 2

Các nghiên cứu liên quan

2.1 Trích xuất đặc trưng hình ảnh với kiến trúc ResNet

Trong sự phát triển bùng nổ của các hệ thống thị giác máy tính hiện đại, khả năng học biểu diễn dữ liệu hay còn gọi là trích xuất đặc trưng đóng vai trò tối quan trọng, quyết định trực tiếp đến hiệu suất và độ chính xác của toàn bộ mô hình. Không có một bộ đặc trưng tốt, các bước phân loại hay nhận dạng phía sau dù được thiết kế tinh vi đến đâu cũng khó có thể bù đắp được.

Trước kỷ nguyên của học sâu, các phương pháp truyền thống buộc phải dựa vào các kỹ thuật trích xuất đặc trưng thủ công (features) như SIFT (Scale-Invariant Feature Transform) hay HOG (Histogram of Oriented Gradients) [9, 10]. Những phương pháp này tuy có hiệu quả nhất định nhưng lại phụ thuộc quá nhiều vào kiến thức tiên nghiệm của chuyên gia, thiếu tính linh hoạt và khó thích nghi với sự đa dạng của dữ liệu tự nhiên. Quan trọng hơn, chúng không có khả năng tự cải thiện khi được cung cấp thêm dữ liệu. Đây là một hạn chế căn bản trong bối cảnh dữ liệu ngày càng phong phú.

Để khắc phục hạn chế đó, đề án này sử dụng mạng neuron tích chập sâu (Deep Convolutional Neural Networks — Deep CNN) nhằm tự động hóa quá trình học các đặc trưng phức tạp trực tiếp từ dữ liệu thô. Trong số các kiến trúc CNN phổ biến, Mạng dư (Residual Networks — ResNet) được lựa chọn làm backbone nhờ vào kiến trúc ưu việt giúp giải quyết triệt để bài toán biến mất đạo hàm, cho phép xây dựng các mô hình rất sâu với khả năng học đặc trưng phân cấp mạnh mẽ.

2.1.1 Vấn đề thoái hóa trong quá trình huấn luyện mạng neuron sâu

Theo lý thuyết học sâu kinh điển, độ sâu của mạng (tức số lượng lớp ẩn xếp chồng lên nhau) có tỷ lệ thuận với khả năng trừu tượng hóa và biểu diễn dữ liệu. Về mặt logic, các tầng đầu tiên sẽ chịu trách nhiệm học các đặc trưng mức thấp như cạnh, góc, màu sắc, trong khi các tầng sâu hơn sẽ tổ hợp chúng lại để nhận diện các đặc trưng ngữ nghĩa phức tạp hơn như bộ phận vật thể hay khuôn mặt.

Tuy nhiên, thực nghiệm mạng tính đột phá [11] đã chỉ ra một nghịch lý đáng ngạc nhiên: khi cố gắng tăng độ sâu của mạng vượt quá một ngưỡng nhất định (ví dụ tăng từ 20 lớp lên 56 lớp), độ chính xác của mô hình không những không tăng mà còn bị bão hòa và giảm sút nghiêm trọng. Điều đáng chú ý là hiện tượng này xảy ra ngay cả trên tập dữ liệu huấn luyện, chứng tỏ đây không phải vấn đề do quá khớp (**overfitting**) mà là một khó khăn nội tại của quá trình tối ưu hóa.

Hiện tượng này được gọi là vấn đề thoái hóa và nguyên nhân sâu xa của nó liên quan mật thiết đến hiện tượng mất đạo hàm (vanishing gradient). Trong quá trình lan truyền ngược để cập nhật trọng số, tín hiệu gradient phải đi qua rất nhiều tầng phi tuyến. Mỗi lần đi qua một tầng có hàm kích hoạt bão hòa (như sigmoid hay tanh trước đây), biên độ của gradient bị nhân với một giá trị nhỏ hơn 1. Khi mạng quá sâu, tích của hàng trăm giá trị nhỏ này dẫn đến gradient suy giảm dần về 0 khi về đến các lớp đầu tiên, khiến các lớp đó gần như không được cập nhật trọng số và không thể học được các đặc trưng hữu ích.

2.1.2 Cơ chế Học phần dư

Để giải quyết nút thắt cổ chai này, kiến trúc ResNet [11] đã ra đời với cơ chế đột phá mang tên "Học phần dư" (Residual Learning). Giả sử $H(\mathbf{x})$ là một hàm ánh xạ lý tưởng mà ta muốn một khối mạng neuron học được từ dữ liệu đầu vào $\mathbf{x}$. Các kiến trúc mạng truyền thống tiếp cận vấn đề bằng cách cố gắng xấp xỉ trực tiếp hàm $H(\mathbf{x})$ này.

ResNet đề xuất một cách tiếp cận hoàn toàn khác biệt: thay vì cố gắng học trực tiếp toàn bộ ánh xạ $H(\mathbf{x})$, mạng được thiết kế lại để học một hàm phần dư $F(\mathbf{x})$, biểu thị sự sai khác giữa đầu vào và đầu ra mong muốn:

$$H(\mathbf{x}) = F(\mathbf{x}, \{W_i\}) + \mathbf{x} \quad (2.1)$$

Về mặt triển khai kiến trúc, ý tưởng này được hiện thực hóa thông qua một đường nối tắt (skip connection). Đường kết nối này cho phép tín hiệu đầu vào $\mathbf{x}$ nhảy cóc qua các lớp trọng số và được cộng trực tiếp vào đầu ra của các lớp biến đổi phi tuyến $F(\mathbf{x})$. Ý nghĩa lý thuyết sâu sắc của kiến trúc này nằm ở hai điểm cốt lõi:

- **Đơn giản hóa bài toán tối ưu hóa:** Trong trường hợp ánh xạ tối ưu cho một tầng nào đó là ánh xạ đồng nhất (tức tầng đó chỉ cần truyền nguyên vẹn thông tin đi), việc đẩy các trọng số của hàm phần dư $F(\mathbf{x})$ về giá trị 0 dễ hơn rất nhiều so với việc phải tìm kiếm một bộ trọng số phức tạp sao cho tích chập của chúng xấp xỉ chính $\mathbf{x}$. Nói cách khác, ResNet tạo ra một "con đường mặc định" hiệu quả khi tầng đó chưa cần học thêm gì.
- **Tạo lập Cầu nối Gradient:** Đây là lợi ích quan trọng nhất giúp huấn luyện mạng sâu. Trong quá trình lan truyền ngược, đạo hàm của hàm mất mát $\mathcal{L}$ đối với đầu vào $\mathbf{x}$ được

phân rã theo quy tắc chuỗi:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}}{\partial H(\mathbf{x})} \left(1 + \frac{\partial F(\mathbf{x})}{\partial \mathbf{x}} \right) \quad (2.2)$$

Sự xuất hiện của hạng tử $+1$ (đến từ đường kết nối tắt) đảm bảo rằng gradient luôn có một đường truyền trực tiếp về các lớp phía trước mà không bị triệt tiêu hay suy giảm, bất kể giá trị đạo hàm của hàm phần dư $F(\mathbf{x})$ có nhỏ đến mức nào. Nhờ cơ chế này, ta có thể huấn luyện thành công các mạng cực sâu (như ResNet-101, ResNet-152) mà vẫn đảm bảo sự hội tụ tốt.

2.1.3 Cấu trúc khối xây dựng cơ bản

Trong phạm vi đồ án này, chúng tôi sử dụng kiến trúc ResNet-18, một biến thể nhẹ nhưng hiệu quả của họ ResNet. Đơn vị cấu thành cơ bản nhất của nó là "Basic Block", là một chuỗi các thao tác xử lý tuần tự được thiết kế tối ưu nhằm trích xuất và tinh chỉnh đặc trưng:

- **Tích chập (Convolution — Conv2d):** Khối sử dụng các bộ lọc có kích thước tiêu chuẩn 3×3 . Đây là thành phần cốt lõi thực hiện các phép toán trích xuất đặc trưng không gian cục bộ. Các bộ lọc này trượt trên toàn bộ không gian ảnh đầu vào, thực hiện phép nhân chập để phát hiện và làm nổi bật các mẫu hình học từ đơn giản đến phức tạp. Kích thước 3×3 được chọn vì nó cân bằng tốt giữa trường tiếp nhận (receptive field) đủ rộng và số lượng tham số hợp lý.
- **Chuẩn hóa theo lô (Batch Normalization — BN):** Lớp này thường được đặt ngay sau lớp tích chập và trước hàm kích hoạt phi tuyến. BN giải quyết vấn đề "dịch chuyển hiệp phương sai nội bộ" (Internal Covariate Shift) [12], tức hiện tượng phân phối đầu vào của mỗi lớp thay đổi liên tục trong quá trình huấn luyện khi các tham số của lớp trước cập nhật. Bằng cách chuẩn hóa đầu ra của mỗi lớp về dạng chuẩn (trung bình 0, phương sai 1), BN ổn định quá trình huấn luyện, cho phép sử dụng learning rate lớn hơn để hội tụ nhanh hơn, đồng thời đóng vai trò như một bộ điều chuẩn nhẹ giúp giảm overfitting.
- **Hàm kích hoạt (Rectified Linear Unit — ReLU):** Sử dụng hàm phi tuyến đơn giản $f(x) = \max(0, x)$. ReLU phá vỡ tính tuyến tính của mô hình, cho phép mạng neuron học được các mối quan hệ phức tạp trong dữ liệu. So với các hàm kích hoạt bão hòa như sigmoid hay tanh, ReLU không bị hiện tượng vanishing gradient ở vùng giá trị dương, giúp tín hiệu gradient truyền qua dễ dàng hơn.

Một chi tiết kỹ thuật quan trọng là thứ tự thực hiện phép cộng kết nối tắt: phép cộng giữa đầu ra nhánh chính $F(\mathbf{x})$ và đầu vào nhánh tắt $\mathbf{x}$ được thực hiện *sau* lớp Batch Norm thứ hai và *trước* hàm kích hoạt ReLU cuối cùng của khối. Việc sắp xếp này đảm bảo rằng thông tin tổng hợp từ cả hai nhánh cũng được đi qua hàm phi tuyến, giúp tăng cường khả năng biểu diễn trước khi chuyển sang khối xử lý tiếp theo.

2.1.4 Quá trình học đặc trưng phân cấp

ResNet, cũng như các mạng CNN hiện đại khác, học đặc trưng theo một cấu trúc phân cấp rõ ràng. Quá trình này được chia thành 4 giai đoạn chính, tương ứng với việc giảm dần kích thước không gian và tăng dần độ sâu kênh của dữ liệu:

- **Tầng đặc trưng mức thấp (Low-level features — Conv1 & Layer1):** Ở các lớp nông đầu tiên, mạng tập trung vào các chi tiết cục bộ như cạnh, góc, và các mảng màu cơ bản. Đối với đầu vào là ảnh CIFAR-10 [13] có kích thước nhỏ (32×32), việc giữ lại độ phân giải không gian cao ở tầng này là rất quan trọng để không làm mất mát thông tin chi tiết. Vì lý do này, trong đồ án, lớp Conv1 nguyên bản kích thước 7×7 với stride 2 được thay thế bằng bộ lọc 3×3 stride 1, và lớp MaxPool đầu tiên được loại bỏ.
- **Tầng đặc trưng mức trung (Mid-level features — Layer2 & Layer3):** Khi tín hiệu đi sâu vào mạng, các đặc trưng mức thấp được tổ hợp lại. Mạng bắt đầu nhận diện được các mẫu họa tiết (textures) và các hình dạng hình học phức tạp hơn như hình tròn, đường cong, hay lưới. Nhờ cơ chế Trường tiếp nhận (Receptive Field) được mở rộng dần qua các lớp tích chập và bước giảm kích thước (stride), mỗi neuron ở tầng này có khả năng "nhìn thấy" và tổng hợp thông tin từ một vùng lớn hơn nhiều trên ảnh gốc.
- **Tầng đặc trưng mức cao (High-level semantic features — Layer4):** Tại các lớp cuối cùng, đặc trưng trở nên rất trừu tượng và mang tính ngữ nghĩa cao (semantic). Thay vì các cạnh hay màu sắc đơn lẻ, mạng biểu diễn các khái niệm bộ phận của vật thể (như bánh xe ô tô, mắt động vật). Đây là các đặc trưng có tính bất biến (invariant) cao đối với các thay đổi nhỏ về vị trí, góc độ hay ánh sáng, là những đặc trưng mà bài toán học biểu diễn liên tục cần để tái sử dụng qua nhiều tác vụ.

Kết thúc quá trình trích xuất đặc trưng là một lớp Gộp trung bình toàn cục (Global Average Pooling — GAP). Lớp này nén toàn bộ thông tin không gian của feature map cuối cùng (ví dụ kích thước $512 \times 4 \times 4$) thành một vector duy nhất (512 chiều). Vector này chính là "embedding" đại diện cho bức ảnh, chứa đựng cô đọng toàn bộ thông tin ngữ nghĩa. Đây là đầu vào trực tiếp cho đầu chiếu phi tuyến (projection head) trong khung học tương phản được trình bày ở Mục 2.3.

2.2 Học liên tục

Học liên tục (continual learning, hay còn gọi là học suốt đời) là mô hình học máy trong đó các hệ thống trí tuệ nhân tạo được huấn luyện để học hỏi từ một luồng dữ liệu liên tục hoặc một chuỗi các tác vụ xuất hiện theo thời gian [1]. Mục tiêu tối thượng là tích lũy tri thức mới mà không làm mất đi hoặc quên lãng những kiến thức đã học từ các tác vụ trong quá khứ, mô phỏng lại khả năng học tập suốt đời của con người. Hiện tượng ngược lại, khi một mạng neuron ghi đè kiến thức cũ khi tiếp thu kiến thức mới, được gọi là "quên thảm khốc" (catastrophic forgetting) [5, 6].

2.2.1 Mâu thuẫn nội tại

Cơ sở lý thuyết giải thích cho các khó khăn trong học liên tục bắt nguồn từ một nghịch lý cơ bản: sự xung đột giữa hai yêu cầu trái ngược mà một hệ thống học tập cần phải thỏa mãn đồng thời.

- **Tính Linh hoạt (Plasticity):** Là khả năng mềm dẻo của hệ thống trong việc thay đổi trạng thái nội tại (các trọng số kết nối) để tiếp thu và tích hợp tri thức mới. Một hệ thống có tính linh hoạt cao sẽ học rất nhanh các tác vụ mới, thích nghi tốt với sự thay đổi của môi trường. Đây là điều kiện cần thiết để hệ thống không bị lỗi thời khi gặp các phân phối dữ liệu chưa từng thấy.
- **Tính Ổn định (Stability):** Là khả năng bền vững của hệ thống trong việc duy trì và bảo vệ các trạng thái đã học, nhằm bảo tồn tri thức cũ trước các sự can nhiễu hoặc ghi đè của luồng dữ liệu mới. Nếu không có tính ổn định, mỗi lần học tác vụ mới đồng nghĩa với việc xóa sạch toàn bộ tri thức tích lũy từ trước.


Trong một mạng neuron nhân tạo có dung lượng bộ nhớ hữu hạn (số lượng tham số cố định), hai đặc tính này luôn ở thế đối nghịch và cạnh tranh tài nguyên với nhau. Tối ưu hoá đặc tính nào quá mức thì hiệu suất tổng thể cũng sẽ bị sụt giảm nghiêm trọng:

- Nếu hệ thống ưu tiên **Linh hoạt**: Chúng ta cho phép các trọng số thay đổi tự do (sử dụng learning rate cao, không áp dụng các ràng buộc). Mô hình hội tụ và học rất nhanh ở tác vụ hiện tại. Tuy nhiên, nó sẽ nhanh chóng ghi đè lên các cấu trúc trọng số đang đại diện cho ký ức cũ, gây ra hiện tượng quên thảm khốc và khiến hiệu suất trên các tác vụ cũ giảm về 0.
- Nếu hệ thống ưu tiên **Ổn định**: Chúng ta khóa chặt các trọng số quan trọng hoặc áp dụng các ràng buộc quá mạnh. Mô hình trở nên cứng nhắc, mất đi khả năng tối ưu hóa cho tác vụ mới, dẫn đến hiệu suất thấp (underfitting) trên dữ liệu mới mặc dù nhớ rất dai kiến thức cũ.

Tìm kiếm điểm cân bằng tối ưu giữa hai cực này, nghĩa là vừa đủ linh hoạt để học cái mới và vừa đủ ổn định để không quên cái cũ, chính là bài toán trung tâm mà mọi phương pháp học liên tục đều phải giải quyết, và cũng là thách thức trực tiếp mà SMC²L hướng tới thông qua hàm mất mát tổng hợp ở Chương 3.

2.2.2 Các phương pháp tiếp cận trong học liên tục

Dựa trên thực trạng các hạn chế của bối cảnh học liên tục, có nhiều hướng tiếp cận để cải thiện, bù đắp cho quá trình học đặc trưng đã được nghiên cứu. Có thể gom thành các nhóm phương pháp lớn như sau:



Hình 2.1: Các phương pháp học liên tục [1].

Phương pháp Hồi tưởng (Replay Methods)

Phương pháp này dựa trên ý tưởng trực quan là "ôn tập lại bài cũ". Hệ thống lưu trữ hoặc tái tạo lại dữ liệu cũ để đưa vào huấn luyện song song với việc học dữ liệu mới. Đây được xem là một trong những hướng tiếp cận hiệu quả nhất hiện nay.

- **Hồi tưởng mẫu (Experience Rehearsal) [14]:** Hệ thống duy trì một bộ nhớ đệm (Memory Buffer) có kích thước giới hạn để lưu trữ trực tiếp một lượng nhỏ các mẫu dữ liệu tiêu biểu của các tác vụ cũ. Khi huấn luyện tác vụ mới, các mẫu này được lấy mẫu ngẫu nhiên và trộn chung vào batch huấn luyện, giúp mô hình tính toán gradient dựa trên cả kiến thức mới và cũ. Phương pháp đơn giản nhưng là nền tảng của hầu hết các phương pháp replay phức tạp hơn, bao gồm cả SMC²L.
- **Hồi tưởng sinh (Generative Replay):** Thay vì lưu dữ liệu thật, mô hình huấn luyện thêm một mạng sinh (như GAN hoặc VAE) để học phân phối xác suất của dữ liệu cũ. Khi cần ôn tập, mô hình sinh này tổng hợp ra các dữ liệu giả lập để huấn luyện lại mạng chính. Hướng này hấp dẫn vì không cần lưu dữ liệu thật, nhưng chất lượng phụ thuộc nhiều vào độ chính xác của mô hình sinh.
- **DER và DER++ [15]:** Replay không chỉ đầu vào đã lưu mà còn cả logits của chúng, chứng cất hiệu quả mô hình cũ vào mô hình hiện tại. Đây là baseline mạnh và đơn giản trong học liên tục tổng quát.
- **iCaRL [16]:** Kết hợp bộ phân loại nearest-mean-of-exemplars với lựa chọn mẫu dựa trên herding và chứng cất tri thức, một trong những phương pháp đầu tiên nhắm vào nhận dạng ảnh tăng cường lớp.

Điểm yếu: Hầu hết các phương pháp hồi tưởng đều phụ thuộc vào nhãn lớp rõ ràng cho cả huấn luyện bộ phân loại lẫn lựa chọn mẫu buffer, làm hạn chế khả năng áp dụng trong bối cảnh không có nhãn mà đề tài này hướng đến.

Phương pháp Điều chuẩn (Regularization-based Methods)

Thay vì tốn bộ nhớ để lưu trữ dữ liệu, phương pháp này áp dụng các ràng buộc toán học lên hàm mất mát để hạn chế sự thay đổi tùy tiện của các trọng số.

- **Điều chuẩn dựa trên trọng số (Elastic Weight Consolidation):** EWC [17] tính toán mức độ quan trọng của từng tham số đối với tác vụ cũ (dựa trên ma trận thông tin Fisher). Các tham số quan trọng bị áp một mức "phạt" nặng nếu thay đổi quá nhiều, trong khi các tham số ít quan trọng hơn được tự do cập nhật để học tác vụ mới.
- **Chú ý cứng vào tác vụ (Hard Attention to the Task) [18]:** Học một tập hợp các mặt nạ nhị phân (binary masks) cho mỗi tác vụ, quyết định neuron nào được phép cập nhật. Các neuron quan trọng với tác vụ cũ bị đóng băng hoàn toàn, trong khi các neuron còn lại tự do thích nghi với tác vụ mới. Khác với EWC dùng "phạt mềm", cách này áp đặt ràng buộc cứng qua cơ chế chú ý.
- **Điều chuẩn dựa trên chức năng (Knowledge Distillation):** Sử dụng kỹ thuật chưng cất tri thức, trong đó mô hình cũ đóng vai trò là giáo viên và mô hình đang học là học sinh. Phương pháp này ép buộc mô hình mới phải duy trì hành vi đầu ra tương tự như mô hình cũ khi xử lý cùng một dữ liệu, nhằm giữ nguyên chức năng của mạng thay vì giữ nguyên giá trị trọng số. Nguyên lý này được kế thừa trực tiếp trong thành phần IRD của Co²L và SMC²L.
- **Điều chuẩn trong không gian hàm (Function space regularization) [19]:** Thay vì ràng buộc trực tiếp các giá trị trọng số như EWC, cách này đề xuất đo lường và điều chuẩn sự thay đổi hành vi của mạng trong không gian hàm số, tức là ràng buộc đầu ra của mạng trên dữ liệu cũ không được thay đổi quá nhiều, bất kể trọng số bên trong thay đổi như thế nào. Cách tiếp cận này linh hoạt hơn và ít bị cứng nhắc hơn so với EWC.

Điểm yếu: Các phương pháp này dễ dẫn đến sự cứng nhắc, khiến mô hình khó học các tác vụ mới nếu chúng quá khác biệt về phân phối so với tác vụ cũ. Hiệu suất cũng thường giảm mạnh khi chuỗi tác vụ kéo dài.

Phương pháp Tối ưu hóa (Optimization-based Methods)

Nhóm phương pháp này can thiệp trực tiếp vào quy trình cập nhật Gradient (đạo hàm) và không gian tham số để tìm ra hướng tối ưu nhất thỏa mãn cả tác vụ cũ và mới. Phương pháp sử dụng kỹ thuật **Chiếu Gradient (Gradient Projection)** để khi cập nhật tham số cho tác vụ mới, vector gradient sẽ được chiếu lên một không gian trực giao với không gian gradient của các tác vụ cũ. Điều này đảm bảo quá trình di chuyển trong không gian tham số để học cái mới không làm tăng giá trị hàm mất mát của các tác vụ đã học.

- **GEM [20]:** Ràng buộc hướng cập nhật tham số sao cho hàm mất mát trên bộ nhớ đệm không tăng, cung cấp diễn giải hình học của chiếu gradient. Tại mỗi bước huấn luyện,

GEM giải một bài toán tối ưu hóa có ràng buộc để tìm vector gradient gần nhất với gradient tác vụ hiện tại nhưng không vi phạm các ràng buộc của tác vụ cũ.

- **A-GEM [21]:** Biến thể mở rộng hiệu quả hơn của GEM, thay vì ràng buộc riêng từng tác vụ, A-GEM chỉ yêu cầu gradient tổng hợp không làm tăng loss trung bình trên toàn bộ buffer. Cách xấp xỉ này giảm đáng kể chi phí tính toán trong khi vẫn giữ được hiệu quả chống quên.

Điểm yếu: Chi phí tính toán và lưu trữ cực kỳ cao do phải duy trì và tính toán các ma trận chiều hoặc xấp xỉ các đạo hàm bậc hai (Hessian matrix) tại mỗi bước huấn luyện.

Phương pháp Kiến trúc (Architecture-based Methods)

Phương pháp này giải quyết vấn đề một cách triệt để bằng cách thay đổi cấu trúc vật lý của mạng neuron hoặc phân chia tài nguyên xử lý riêng biệt cho từng tác vụ nhằm tránh sự can thiệp lẫn nhau (interference). Thay vì cố gắng cân bằng giữa học mới và nhớ cũ trong cùng một tập tham số cố định, vốn là nguồn gốc của mâu thuẫn Ổn định & Linh hoạt, nhóm phương pháp này loại bỏ hoàn toàn sự xung đột đó bằng cách đảm bảo mỗi tác vụ có không gian tham số riêng, không chồng lấn. Đây là hướng tiếp cận có nền tảng lý thuyết vững chắc nhất trong việc chống lại "quên thảm khốc", nhưng cũng đặt ra những thách thức thực tiễn nghiêm trọng về khả năng mở rộng.

- **Mở rộng mạng (Dynamic Expansion):** Hệ thống tự động thêm các lớp, các nhánh hoặc các neuron mới vào kiến trúc mạng mỗi khi có tác vụ mới xuất hiện. Phần mạng cũ được đóng băng hoàn toàn để bảo toàn tri thức, trong khi phần mở rộng chịu trách nhiệm học cái mới. Ưu điểm nổi bật là hiện tượng quên thảm khốc gần như không xảy ra vì các tham số của tác vụ cũ không bao giờ bị cập nhật. Tuy nhiên, kích thước mô hình tăng trưởng tuyến tính theo số lượng tác vụ, dẫn đến bộ nhớ và chi phí tính toán không thể kiểm soát khi chuỗi tác vụ kéo dài.
- **Cô lập tham số (Parameter Isolation):** Thay vì mở rộng mạng, hướng này giữ nguyên kích thước tổng thể của mô hình nhưng sử dụng các kỹ thuật phân vùng để dành riêng một tập hợp tham số cho từng tác vụ. Hai kỹ thuật phổ biến nhất là:
 - **Cắt tỉa lặp (Iterative Pruning):** Sau khi huấn luyện xong một tác vụ, hệ thống xác định và cắt tỉa các trọng số ít quan trọng nhất (có giá trị tuyệt đối nhỏ). Các trọng số còn lại được đóng băng vĩnh viễn, trong khi phần đã cắt tỉa được tái sử dụng để học tác vụ tiếp theo. PackNet [22] đã ứng dụng, và chứng minh được rằng một mạng neuron điển hình thường dư thừa tham số đáng kể, cho phép nén nhiều tác vụ vào một kiến trúc duy nhất mà không làm giảm hiệu suất một cách đáng kể.
 - **Mặt nạ nhị phân (Binary Masks):** Học một tập hợp mặt nạ nhị phân đặc trưng cho từng tác vụ, quyết định neuron nào được kích hoạt khi xử lý tác vụ đó. Khi chuyển

sang tác vụ mới, chỉ các neuron chưa được quy hoạch mới được phép cập nhật, cho phép tối ưu hóa đầu và cuối trong khi vẫn bảo vệ tri thức cũ.

Một điểm quan trọng cần lưu ý là các phương pháp kiến trúc thường hoạt động tốt nhất trong kịch bản Task-IL, nơi Task ID được cung cấp tại thời điểm kiểm thử để kích hoạt đúng nhánh hoặc mặt nạ tương ứng. Trong kịch bản Class-IL khó hơn, khi không có Task ID, hệ thống phải tự suy luận tác vụ nào phù hợp, một bài toán phụ không tầm thường làm giảm đáng kể hiệu suất thực tế.

Điểm yếu: Với hướng mở rộng động, kích thước mô hình sẽ phình to không giới hạn theo thời gian, gây tốn kém tài nguyên bộ nhớ và tính toán, đặc biệt bất khả thi trên các thiết bị nhúng như drone hay hệ thống nhúng với tài nguyên hạn chế. Với hướng cô lập tham số, dung lượng học tập của mạng bị giới hạn cứng bởi kích thước kiến trúc ban đầu: khi toàn bộ tham số đã được phân bổ cho các tác vụ trước, hệ thống hoàn toàn mất khả năng học tác vụ mới mà không ghi đè lên tri thức cũ. Ngoài ra, cả hai hướng đều yêu cầu biết trước (hoặc ước lượng được) tổng số tác vụ để phân bổ tài nguyên hợp lý, một giả định thường không thực tế trong các ứng dụng học liên tục thực tế.

Phương pháp Học biểu diễn (Representation Learning)

Phương pháp này tiếp cận vấn đề từ gốc rễ bằng cách tập trung xây dựng một không gian biểu diễn đặc trưng tổng quát, mạnh mẽ và có tính phân biệt cao ngay từ đầu, giúp giảm thiểu sự chồng chập không gian đặc trưng giữa các tác vụ. Thay vì cố gắng bảo toàn ranh giới quyết định hay ràng buộc trọng số như các nhóm phương pháp trước, hướng tiếp cận này giả định nếu mô hình học được một không gian biểu diễn đủ tốt ngay từ đầu, nghĩa là một không gian đặc trưng thưa, tách biệt và bất biến với các biến đổi bề mặt, thì sẽ giúp việc thêm kiến thức mới ít gây xáo trộn và ảnh hưởng đến kiến thức cũ hơn.

Phương pháp gồm các kỹ thuật tiên tiến như Học tự giám sát (Self-supervised Learning) và Học tương phản (Contrastive Learning) để dạy mô hình hiểu sâu cấu trúc nội tại của dữ liệu mà không cần nhãn. Các ví dụ tiêu biểu bao gồm:

- **SimCLR [2]:** Học biểu diễn bằng cách tối đa hóa độ tương đồng giữa hai view tăng cường của cùng một ảnh, đồng thời đẩy xa các ảnh khác nhau trong không gian đặc trưng. SimCLR không yêu cầu nhãn lớp ở bất kỳ bước nào, tạo ra các đặc trưng có tính Task-Agnostic cao, không bị ràng buộc bởi ranh giới lớp của bất kỳ tác vụ cụ thể nào, và do đó dễ tái sử dụng xuyên suốt chuỗi tác vụ liên tục.
- **LUMP [7]:** Áp dụng nội suy Mixup giữa mẫu tác vụ hiện tại và mẫu trong buffer ở cấp độ đầu vào pixel, tạo ra cầu nối liên tục qua ranh giới tác vụ. Thay vì chỉ học trên dữ liệu tác vụ mới, LUMP buộc không gian biểu diễn phải chuyển tiếp mượt mà giữa phân phối cũ và mới, giảm thiểu hiện tượng dịch chuyển đặc trưng đột ngột (feature drift), vốn là điểm yếu thường gặp của các phương pháp tự giám sát liên tục thuần túy.

- **Co²L [4]:** Kết hợp học tương phản có giám sát với cơ chế chưng cất quan hệ theo mẫu để vừa học biểu diễn phân tách tốt theo lớp vừa bảo toàn cấu trúc hình học của tri thức cũ. Co²L là một trong những công trình đầu tiên chứng minh rằng học tương phản vượt trội hơn học có giám sát truyền thống trong kịch bản Class-Incremental Learning, nhờ tránh được thiên kiến đối với lớp mới học.

Điểm yếu: Thường đòi hỏi khối lượng tính toán lớn, thời gian huấn luyện lâu và kỹ thuật huấn luyện phức tạp. Cụ thể, học tương phản yêu cầu batch size lớn để có đủ mẫu âm tính chất lượng, pipeline tăng cường dữ liệu tinh tế để định nghĩa cặp dương tính có ý nghĩa, và chiến lược quản lý mẫu âm cẩn thận để tránh *false negative*, tức hai mẫu cùng lớp ngữ nghĩa nhưng bị coi là âm tính do không có nhãn. Ngoài ra, giai đoạn đánh giá thường đòi hỏi thêm bước Linear Probing hoặc fine-tuning riêng biệt, làm tăng độ phức tạp của quy trình triển khai so với các phương pháp có giám sát trực tiếp. Đây chính là hướng tiếp cận mà đề tài này theo đuổi và nỗ lực cải tiến thông qua khung đề xuất SMC²L sẽ trình bày ở Chương 3.

2.2.3 Các kịch bản thiết lập bài toán trong Học liên tục

Bài toán học liên tục được phân loại thành ba kịch bản chính dựa trên mức độ sẵn có của thông tin định danh tác vụ (Task Identity) tại thời điểm kiểm thử. Theo quy chuẩn chung của cộng đồng nghiên cứu [23], sự phân loại này không chỉ đơn thuần là học thuật mà phản ánh trực tiếp mức độ khó khăn thực tế và yêu cầu thiết kế của từng bài toán. Ba kịch bản tạo thành một thang độ khó tăng dần, trong đó mỗi cấp độ loại bỏ thêm một giả định thuận lợi so với cấp trước.

Học tăng cường Tác vụ (Task-Incremental Learning — Task-IL)

Đây là kịch bản đơn giản và dễ giải quyết nhất trong ba kịch bản. Mô hình được cung cấp thông tin Task ID rõ ràng ở cả quá trình huấn luyện lẫn kiểm thử. Tức là tại thời điểm suy luận, hệ thống luôn biết trước mình đang xử lý dữ liệu thuộc tác vụ nào. Do có thông tin định danh này, mô hình thường được thiết kế với kiến trúc đa đầu (multi-head), mỗi tác vụ có một lớp đầu ra riêng biệt với tập nhãn độc lập. Khi kiểm thử, hệ thống chỉ kích hoạt đầu ra tương ứng với Task ID được cung cấp, bỏ qua hoàn toàn các đầu ra của các tác vụ khác.

Vấn đề quên thảm khốc ít xảy ra trong kịch bản này vì các không gian quyết định của từng tác vụ được tách biệt rạch ròi về mặt kiến trúc, giảm thiểu tối đa sự can thiệp lẫn nhau giữa các tác vụ. Thực chất, Task-IL gần giống với bài toán học đa tác vụ truyền thống, với sự khác biệt duy nhất là dữ liệu đến tuần tự thay vì song song. Chính vì vậy, hầu hết các phương pháp học liên tục, kể cả những phương pháp đơn giản nhất, đều đạt hiệu suất cao trong kịch bản này và Task-IL thường được dùng như một giới hạn trên để kiểm tra tính đúng đắn của hệ thống.

Học tăng cường Miền dữ liệu (Domain-Incremental Learning — Domain-IL)

Trong kịch bản này, cấu trúc đầu ra của bài toán là không đổi, nghĩa là số lượng lớp cần phân loại giữ nguyên xuyên suốt toàn bộ chuỗi tác vụ, nhưng phân phối thống kê của dữ liệu đầu vào

thay đổi liên tục theo thời gian. Quan trọng hơn, Task ID không được cung cấp tại thời điểm kiểm thử, buộc mô hình phải tự thích nghi mà không có bất kỳ gợi ý nào về nguồn gốc của dữ liệu đầu vào. Mô hình phải giải quyết cùng một bài toán cốt lõi nhưng trong các điều kiện môi trường hoặc bối cảnh hoàn toàn khác nhau, ví dụ nhận dạng chữ số viết tay ở các góc xoay khác nhau, hay phân loại đối tượng dưới các điều kiện ánh sáng và điều kiện thời tiết biến đổi.

Thách thức chính của Domain-IL nằm ở khả năng tổng quát hóa xuyên miền (cross-domain generalization): mô hình phải học các đặc trưng bất biến với sự thay đổi miền dữ liệu trong khi vẫn duy trì khả năng phân biệt giữa các lớp. Đây là kịch bản trung gian về độ khó. Nó khó hơn Task-IL vì không có Task ID, nhưng dễ hơn Class-IL vì không gian nhãn không thay đổi. Trong đề án, tập dữ liệu R-MNIST, xây dựng bằng cách xoay ảnh MNIST với 20 góc khác nhau lấy đều trong $[0, \pi)$, được sử dụng để đánh giá mô hình trong kịch bản này, mô phỏng tình huống cảm biến thu thập dữ liệu ở các góc nhìn thay đổi liên tục theo thời gian.

Học tăng cường Lớp (Class-Incremental Learning — Class-IL)

Đây là kịch bản khó khăn và thực tế nhất trong ba kịch bản, đồng thời là trọng tâm của đề tài. Không gian nhãn mở rộng dần theo thời gian: mô hình phải học thêm các nhóm lớp đối tượng mới ở mỗi tác vụ, nhưng tại thời điểm kiểm thử phải có khả năng phân loại chính xác tất cả các lớp đã tích lũy từ trước đến nay trong một đầu ra duy nhất mà không được biết trước Task ID. Mô hình không có bất kỳ gợi ý nào về việc ảnh đầu vào thuộc về tác vụ nào và phải tự suy luận ra nhãn đúng trong toàn bộ không gian nhãn ngày càng mở rộng.

Thách thức đặc trưng của Class-IL là hiện tượng *Inter-task Confusion*: sau khi học xong tác vụ mới, các tham số của lớp đầu ra tương ứng với các lớp mới vừa được cập nhật mạnh mẽ, trong khi các tham số của lớp cũ không được cập nhật và dần bị lỗi thời. Hệ quả là đầu ra logits của các lớp mới có xu hướng lớn hơn đáng kể, khiến mô hình bị bias mạnh về phía dự đoán các lớp mới học và bỏ qua gần như hoàn toàn các lớp cũ, ngay cả khi dữ liệu đầu vào rõ ràng thuộc về lớp cũ. Đây chính là lý do tại sao hầu hết các phương pháp học giám sát truyền thống, dù hoạt động tốt trong Task-IL, đều thất bại nghiêm trọng trong Class-IL với độ chính xác thường chỉ nhỉnh hơn ngẫu nhiên.

Ngược lại, học tương phản có ưu thế tự nhiên trong kịch bản này vì nó không tối ưu hóa ranh giới quyết định tuyến tính giữa các lớp cụ thể. Thay vào đó, mục tiêu tương phản xây dựng một không gian biểu diễn có tính Uniformity cao, các đặc trưng phân bố đều trên không gian hypersphere giúp giai đoạn Linear Probing phía sau có thể phân tách công bằng tất cả các lớp mà không bị thiên vị về phía lớp mới. Đây là cốt lõi lý giải tại sao SMC²L, dù không dùng nhãn, vẫn đạt hiệu suất tốt trong kịch bản Class-IL so với các phương pháp có giám sát truyền thống.

2.2.4 Các chỉ số đánh giá học liên tục

Để đánh giá toàn diện hiệu năng của một hệ thống học liên tục, chúng ta không chỉ quan tâm đến độ chính xác tại thời điểm hiện tại mà còn phải đo lường khả năng ghi nhớ và tác động tương hỗ giữa các tác vụ. Giả sử $a_{i,j}$ là độ chính xác của mô hình trên tập kiểm thử của tác vụ j sau khi mô hình đã học xong tác vụ i , và T là tổng số tác vụ.

Độ chính xác trung bình (Average Accuracy — A_T)

Đây là chỉ số quan trọng nhất, đo lường khả năng hoạt động tổng quát của mô hình trên tất cả các tác vụ đã học sau khi quá trình huấn luyện toàn bộ kết thúc:

$$A_T = \frac{1}{T} \sum_{j=1}^T a_{T,j} \quad (2.3)$$

Giá trị A_T càng cao chứng tỏ mô hình càng hiệu quả trong việc giải quyết toàn bộ chuỗi tác vụ mà không bị quên.

Độ quên (Forgetting Measure — F_T)

Chỉ số này định lượng mức độ suy giảm hiệu suất của một tác vụ cụ thể so với thời điểm phong độ tốt nhất của nó (thường là ngay sau khi nó vừa được học xong):

$$F_T = \frac{1}{T-1} \sum_{j=1}^{T-1} \max_{l \in \{1, \dots, T-1\}} (a_{l,j} - a_{T,j}) \quad (2.4)$$

Giá trị F_T càng thấp càng tốt, cho thấy mô hình ít bị quên theo thời gian.

Khả năng chuyển giao ngược (Backward Transfer — BWT)

Chỉ số này đo lường sự ảnh hưởng của việc học tác vụ mới lên hiệu suất của các tác vụ cũ.

$$BWT = \frac{1}{T-1} \sum_{j=1}^{T-1} (a_{T,j} - a_{j,j}) \quad (2.5)$$

Giá trị $BWT < 0$ cho thấy việc học cái mới làm giảm hiệu suất cái cũ, mức âm càng lớn thì quên lãng càng nghiêm trọng. Một hệ thống học liên tục lý tưởng sẽ có BWT gần bằng 0 hoặc dương.

2.3 Học biểu diễn Tương phản

2.3.1 Nguyên lý cơ bản

Trong kỷ nguyên của Học sâu, việc phụ thuộc vào dữ liệu được dán nhãn thủ công đang trở thành nút thắt cổ chai, đặc biệt là trong các bài toán học liên tục nơi dữ liệu mới xuất hiện

không ngừng. Học biểu diễn tương phản nổi lên như một phương pháp tiếp cận chủ đạo trong lĩnh vực Học tự giám sát, cho phép mô hình học được các đặc trưng ngữ nghĩa mạnh mẽ từ dữ liệu thô mà không cần nhãn.

Ý tưởng cốt lõi của học tương phản là học cách phân biệt từng cá thể dữ liệu riêng biệt trong không gian đặc trưng. Cho một tập dữ liệu $D = \{x_1, x_2, \dots, x_N\}$, mục tiêu là học một hàm ánh xạ $f_\theta(\cdot)$ sao cho các biến thể khác nhau của cùng một mẫu dữ liệu x_i sẽ được ánh xạ về các điểm gần nhau trong không gian vector (Alignment), trong khi các mẫu dữ liệu khác nhau x_j ($j \neq i$) sẽ bị đẩy ra xa nhau (Uniformity). Quá trình này dựa trên việc xây dựng các cặp mẫu:

- **Cặp dương tính (Positive Pair):** Hai phiên bản biến thể $(\tilde{x}_i, \tilde{x}_j)$ được sinh ra từ cùng một ảnh gốc x thông qua tăng cường dữ liệu. Chúng chia sẻ cùng nội dung ngữ nghĩa dù khác biệt về màu sắc, góc cắt, hay độ tương phản.
- **Cặp âm tính (Negative Pair):** Các cặp được tạo thành từ ảnh gốc x và bất kỳ ảnh nào khác trong tập dữ liệu. Đây là các mẫu có nội dung ngữ nghĩa khác nhau mà mô hình cần học cách phân biệt.

2.3.2 Khung xử lý chính

Pipeline học tương phản bao gồm bốn thành phần nối tiếp nhau, tạo thành một luồng biến đổi liên tục từ ảnh thô đến không gian biểu diễn tối ưu:

$$x \xrightarrow{\mathcal{A}} \tilde{x} \xrightarrow{f} \mathbf{h} \xrightarrow{g} \mathbf{z} \xrightarrow{\mathcal{L}} \text{gradient}$$

Cụ thể, x là ảnh gốc đầu vào; $\mathcal{A}$ là tập hợp các phép tăng cường dữ liệu ngẫu nhiên, biến đổi x thành hai view $\tilde{x}$ và $\tilde{x}'$ đóng vai trò cặp dương tính; $f(\cdot)$ là mạng mã hóa (encoder) trích xuất vector đặc trưng $\mathbf{h} \in \mathbb{R}^{d_h}$ từ mỗi view, đây là biểu diễn được sử dụng cho các tác vụ liên tục; $g(\cdot)$ là đầu chiếu phi tuyến (projection head) ánh xạ $\mathbf{h}$ sang không gian nhỏ hơn $\mathbf{z} \in \mathbb{R}^{d_z}$ nơi hàm mất mát $\mathcal{L}$ được tính toán; cuối cùng gradient từ $\mathcal{L}$ lan truyền ngược để cập nhật toàn bộ tham số của f và g . Mỗi thành phần đảm nhiệm một vai trò cụ thể và không thể thiếu: module tăng cường dữ liệu định nghĩa bài toán (cặp nào là dương tính), mạng mã hóa học *biểu diễn*, đầu chiếu bảo vệ *thông tin hữu ích*, và hàm mất mát cung cấp *tín hiệu tối ưu hóa*.

Module Tăng cường dữ liệu ngẫu nhiên

Cho một mẫu dữ liệu x , module này áp dụng ngẫu nhiên hai phép biến đổi $\mathcal{T}$ và $\mathcal{T}'$ để tạo ra hai khung nhìn (views) tương ứng:

$$\tilde{x}_i = \mathcal{T}(\mathbf{x}), \quad \tilde{x}_j = \mathcal{T}'(\mathbf{x}) \quad \text{với } \mathcal{T}, \mathcal{T}' \sim \mathcal{A} \quad (2.6)$$

Hai views từ cùng một ảnh gốc được coi là "dương tính" với nhau vì chúng chia sẻ cùng nội dung ngữ nghĩa, dù khác biệt về màu sắc, góc cắt, hay độ tương phản. Điều này khác căn bản so

với học có giám sát, khái niệm "giống nhau" không được định nghĩa bởi nhãn lớp, mà bởi tính bất biến ngữ nghĩa dưới phép biến đổi. Nếu không có bước tăng cường, mạng neuron có thể tìm ra các đường tắt như dựa vào biểu đồ màu hay vị trí tuyệt đối của đối tượng để phân biệt các ảnh mà không thực sự hiểu nội dung đặc trưng hình học.

Mạng mã hóa cơ sở (Encoder)

Một mạng neuron $f(\cdot)$ trích xuất vector biểu diễn từ các view đã tăng cường:

$$\mathbf{h}_i = f(\tilde{\mathbf{x}}_i) \in \mathbb{R}^{d_h} \quad (2.7)$$

Tại đây, $\mathbf{h}_i$ là vector đặc trưng được sử dụng cho các tác vụ phân loại sau này. Trong ngữ cảnh học liên tục, chất lượng của $\mathbf{h}_i$ quyết định trực tiếp khả năng chuyển giao tri thức giữa các tác vụ: một không gian $\mathbf{h}$ có tính Task-Agnostic cao, tức không bị ràng buộc bởi ranh giới lớp của bất kỳ tác vụ cụ thể nào, sẽ dễ tái sử dụng hơn và ít bị ảnh hưởng bởi hiện tượng quên thảm khốc. Đây là một trong những lợi thế cốt lõi của học tương phản so với học có giám sát trong bối cảnh học liên tục.

Đầu chiếu (Projection Head)

Một mạng MLP nhỏ $g(\cdot)$ ánh xạ vector biểu diễn sang không gian tiềm ẩn nơi hàm mất mát được áp dụng:

$$\mathbf{z}_i = g(\mathbf{h}_i) = W^{(2)} \sigma(W^{(1)} \mathbf{h}_i) \in \mathbb{R}^{d_z} \quad (2.8)$$

Trong đó σ là hàm kích hoạt ReLU. Vai trò của đầu chiếu là bảo vệ thông tin hữu ích trong $\mathbf{h}_i$: hàm mất mát tương phản có xu hướng loại bỏ các thông tin biến thiên (như màu sắc, hướng xoay) để đạt được tính bất biến. Bằng cách tính loss trên $\mathbf{z}_i$ thay vì trực tiếp trên $\mathbf{h}_i$, các thông tin bị loại bỏ ở $\mathbf{z}_i$ nhưng vẫn được giữ lại ở $\mathbf{h}_i$, giúp $\mathbf{h}_i$ giàu thông tin hơn cho các tác vụ liên tục. Sau quá trình huấn luyện, đầu chiếu được loại bỏ và chỉ giữ lại $f(\cdot)$ cho giai đoạn đánh giá tuyến tính (Linear Probing).

Hàm mất mát InfoNCE

Đây là thành phần toán học quan trọng nhất, định hướng cho toàn bộ quá trình tối ưu hóa. Hàm InfoNCE (Noise Contrastive Estimation) [2] là một dạng Cross-Entropy áp dụng cho bài toán phân loại: với một batch gồm N mẫu dữ liệu gốc, sau khi tăng cường ta có $2N$ điểm dữ liệu. Với một cặp dương tính (i, j) , ta coi các $2N - 1$ điểm còn lại là các mẫu âm tính. Hàm đo độ tương đồng sử dụng Cosine Similarity:

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad (2.9)$$

Hàm mất mát cho một cặp dương tính (i, j) :

$$\mathcal{L}_{i,j} = -\log \frac{\exp\left(\frac{\langle \mathbf{z}_i, \mathbf{z}_j \rangle}{\tau}\right)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp\left(\frac{\langle \mathbf{z}_i, \mathbf{z}_k \rangle}{\tau}\right)} \quad (2.10)$$

Trong đó τ là tham số nhiệt độ (temperature scaling) và $\mathbf{1}_{[k \neq i]}$ là hàm chỉ thị bằng 1 nếu $k \neq i$. Tử số tối đa hóa độ tương đồng với cặp dương tính, trong khi mẫu số chuẩn hóa trên toàn bộ batch.

Hàm mất mát tổng quát trên toàn bộ batch:

$$\mathcal{L} = \frac{1}{2N} \sum_{k=1}^N [\mathcal{L}_{2k-1, 2k} + \mathcal{L}_{2k, 2k-1}] \quad (2.11)$$

2.3.3 Cơ chế hoạt động của Gradient và vai trò của Nhiệt độ τ

Để hiểu sâu hơn về cách mô hình học, ta phân tích đạo hàm của hàm loss đối với điểm dữ liệu neo $\mathbf{z}_i$. Đặt $s_{i,k} = \mathbf{z}_i^\top \mathbf{z}_k / \tau$ (giả sử vector đã chuẩn hóa). Gradient có dạng:

$$\frac{\partial \mathcal{L}_{i,j}}{\partial \mathbf{z}_i} = \frac{1}{\tau} \left(\sum_{k \neq i} P_{i,k} \mathbf{z}_k - \mathbf{z}_j \right) \quad (2.12)$$

Trong đó $P_{i,k}$ là xác suất hậu nghiệm (từ hàm Softmax) mà mô hình dự đoán $\mathbf{z}_k$ là cặp dương tính của $\mathbf{z}_i$:

$$P_{i,k} = \frac{\exp(s_{i,k})}{\sum_{m \neq i} \exp(s_{i,m})} \quad (2.13)$$

Thành phần $-\mathbf{z}_j$ kéo $\mathbf{z}_i$ về phía $\mathbf{z}_j$ (cặp dương tính), trong khi thành phần $\sum_{k \neq i} P_{i,k} \mathbf{z}_k$ đẩy $\mathbf{z}_i$ ra xa khỏi các mẫu âm tính với trọng số $P_{i,k}$. Các mẫu âm tính "khó" (hard negatives), tức những mẫu có vector $\mathbf{z}_k$ rất giống $\mathbf{z}_i$, có $P_{i,k}$ lớn và do đó nhận được lực đẩy mạnh hơn từ gradient. Đây là cơ chế "tự động khai thác hard negatives" mà không cần kỹ thuật lấy mẫu đặc biệt như trong các phương pháp metric learning cổ điển.

Tham số nhiệt độ τ điều tiết sự tập trung của gradient. Khi $\tau \rightarrow \infty$, phân phối $P_{i,k}$ trở nên đồng đều, lực đẩy được chia đều cho tất cả các mẫu âm tính và mô hình học chậm, đặc trưng không sắc nét. Khi $\tau \rightarrow 0$, phân phối trở nên cực nhọn, toàn bộ lực đẩy tập trung vào 1-2 mẫu khó nhất, dễ gây mất ổn định nếu mẫu đó thực sự cùng lớp ngữ nghĩa với $\mathbf{z}_i$ (hiện tượng false negative). Giá trị $\tau = 0.07$ là điểm thực nghiệm tối ưu được sử dụng.

2.3.4 Phân tích đặc tính hình học

Theo [24], hàm mất mát InfoNCE đang nỗ lực tối ưu hóa đồng thời hai thuộc tính hình học đối nghịch nhưng bổ trợ lẫn nhau trên không gian đặc trưng chuẩn hóa (Hypersphere $\mathcal{S}^{d-1}$). Việc phân tích hai thuộc tính này không chỉ giúp hiểu sâu hơn về cơ chế của học tương phản, mà còn trực tiếp giải thích tại sao học tương phản phù hợp với bài toán học liên tục hơn so với học có giám sát thuần túy.

Tính liên kết

Tính liên kết (Alignment) đại diện cho khả năng của mô hình trong việc duy trì sự ổn định của biểu diễn đặc trưng khi dữ liệu đầu vào bị thay đổi bởi các phép biến đổi không làm thay đổi ngữ nghĩa:

$$\mathcal{L}_{\text{align}}(f; \alpha) \triangleq \mathbb{E}_{(x,y) \sim p_{\text{pos}}} [\|f(x) - f(y)\|_2^\alpha] \quad (2.14)$$

Trong đó p_{pos} là phân phối của các cặp dương tính, $f(\cdot)$ ánh xạ dữ liệu vào mặt cầu đơn vị ($\|f(x)\|_2 = 1$), và $\alpha = 2$ tương ứng với khoảng cách Euclidean bình phương. Alignment giống như một "lực hấp dẫn" buộc mạng neuron phải học được các đặc trưng bất biến: dù đầu vào thay đổi thế nào về màu sắc hay góc cắt, miễn là nội dung ngữ nghĩa vẫn vậy, thì $f(x)$ và $f(y)$ phải nằm gần nhau trên mặt cầu.

Tuy nhiên, nếu chỉ tối ưu hóa duy nhất Alignment, mô hình sẽ rơi vào trạng thái "Sụp đổ đặc trưng": để đạt $\mathcal{L}_{\text{align}} = 0$, mô hình chỉ cần ánh xạ *tất cả* mọi hình ảnh đầu vào về cùng một vector hằng số duy nhất, hoàn toàn vô dụng cho phân loại. Đây là lý do ta cần thuộc tính thứ hai: Uniformity.

Tính đồng nhất

Tính đồng nhất (Uniformity) đóng vai trò đẩy, ngăn cản các đặc trưng tụ tập lại một chỗ và buộc chúng phải phân bố rải rác khắp mặt cầu:

$$\mathcal{L}_{\text{uniform}}(f; t) \triangleq \log \mathbb{E}_{x,y \stackrel{i.i.d}{\sim} p_{\text{data}}} \left[e^{-t\|f(x)-f(y)\|_2^2} \right] \quad (2.15)$$

Trong đó $t > 0$ là tham số điều chỉnh độ mạnh của lực đẩy. Tối thiểu hóa $\mathcal{L}_{\text{uniform}}$ tương đương với tối đa hóa Entropy của phân phối đặc trưng trên mặt cầu, nghĩa là buộc các điểm dữ liệu phải dàn trải đều nhất có thể. Điều này mang lại hai lợi ích: (1) khả năng phân tách tuyến tính tốt hơn, bởi vì xác suất để các lớp khác nhau bị chồng lấn là thấp nhất; (2) ngăn sụp đổ đặc trưng, bởi vì hàm Gaussian RBF kernel $e^{-t\|x-y\|^2}$ tăng vọt khi hai vector lại gần nhau, tạo ra lực đẩy mạnh.

Sự cân bằng trong InfoNCE và kết nối với học liên tục

Hàm mất mát InfoNCE thực chất là cách tiếp cận tiệm cận để tối ưu hóa tổng của hai hàm mất mát trên:

$$\mathcal{L}_{\text{InfoNCE}} \approx \mathcal{L}_{\text{Alignment}} + \lambda \mathcal{L}_{\text{Uniformity}}$$

Tử số của InfoNCE (log-exp của cặp dương) tối ưu hóa Alignment; mẫu số (tổng log-exp của các cặp âm) tối ưu hóa Uniformity.

Quan trọng hơn, hiểu được Alignment–Uniformity cũng giúp lý giải tại sao học tương phản đặc biệt phù hợp với học liên tục. Khi mô hình học tác vụ mới, không gian đặc trưng cần mở rộng để chứa thêm các cụm mới mà không phá vỡ các cụm cũ. Một không gian có Uniformity cao, tức các đặc trưng được trải đều trên mặt cầu, cung cấp "dư địa" cho các lớp mới phát triển mà không buộc phải ghi đè lên vùng không gian của tri thức cũ. Ngược lại, các phương pháp học có giám sát tối ưu hóa ranh giới quyết định tuyến tính có xu hướng nén các đặc trưng vào các vùng hẹp, làm giảm khả năng mở rộng và dẫn đến xung đột giữa các tác vụ. Đây chính là nền tảng lý thuyết cho hướng tiếp cận của Co²L và SMC²L.

2.4 Baseline Co²L và động lực của SMC²L

2.4.1 Co²L: Học liên tục dựa trên tương phản

Phương pháp Co²L đã kết hợp hai nền tảng lý thuyết cốt lõi: học liên tục với bài toán cân bằng ổn định – linh hoạt, và học tương phản với cơ chế Alignment – Uniformity và đạt được nhiều thành công nhất định.

Co²L [4] là một trong những nghiên cứu đầu tiên chỉ ra rằng việc học biểu diễn thông qua học tương phản, thay vì tối ưu hóa ranh giới quyết định có giám sát, có thể giảm thiểu hiện tượng quên thảm khốc hiệu quả hơn các phương pháp học giám sát truyền thống. Ý tưởng cốt lõi bắt nguồn từ nhận định rằng hầu hết các phương pháp học liên tục có giám sát thực chất đang giải quyết sai bài toán: họ cố gắng bảo toàn *ranh giới quyết định* giữa các lớp, trong khi điều quan trọng hơn là bảo toàn *cấu trúc hình học* của không gian biểu diễn.

Hàm mất mát tương phản có giám sát (SupCon)

Co²L sử dụng Supervised Contrastive Learning (SupCon) [25] làm thành phần tương phản chính. SupCon coi tất cả các mẫu cùng nhãn lớp trong batch là cặp dương tính, không chỉ riêng hai view tăng cường của cùng một ảnh:

$$\mathcal{L}^{\text{sup}} = \sum_{i \in \mathcal{I}} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(\mathbf{z}_i \cdot \mathbf{z}_p / \tau)}{\sum_{k \in \mathcal{A}(i)} \exp(\mathbf{z}_i \cdot \mathbf{z}_k / \tau)} \quad (2.16)$$

trong đó $P(i)$ là tập hợp tất cả chỉ số trong batch chia sẻ nhân với mẫu i , và $\mathcal{A}(i) = \mathcal{I} \setminus \{i\}$.

So với SimCLR thuần, SupCon sử dụng nhiều mẫu dương tính hơn từ thông tin nhân, giúp biểu diễn phân tách tốt hơn theo cấu trúc lớp ngữ nghĩa. Tuy nhiên, điều này đồng nghĩa với việc quá trình huấn luyện bị phụ thuộc hoàn toàn vào nhân lớp, đây là hạn chế sẽ được phân tích ở Mục 2.4.2.

Hàm mất mát chưng cất quan hệ (IRD)

Đóng góp sáng tạo nhất của Co²L là hàm mất mát *Instance-wise Relation Distillation* (IRD), lấy cảm hứng từ nguyên lý chưng cất cấu trúc quan hệ trong SEED [26]. SEED chỉ ra rằng cấu trúc quan hệ do encoder tạo ra có thể được chuyển giao hiệu quả thông qua các mục tiêu chưng cất bảo toàn độ tương đồng theo cặp, thay vì chỉ khớp logits thô. Co²L áp dụng nguyên lý này theo chiều thời gian: thay vì chưng cất từ teacher sang student nhỏ hơn, IRD chưng cất từ mô hình *quá khứ* sang mô hình *hiện tại*, bảo toàn cấu trúc tương đồng theo cặp giữa các mẫu trong buffer.

Thay vì ép buộc mô hình hiện tại phải có vector đặc trưng y hệt mô hình cũ (gây ra sự cứng nhắc làm cản trở học tác vụ mới), IRD ép buộc *mỗi quan hệ tương quan* giữa các mẫu trong bộ nhớ đệm phải được bảo toàn. Cụ thể, nếu trong quá khứ mẫu ảnh A có độ tương đồng với mẫu B cao hơn mẫu C, thì ở tác vụ hiện tại, cấu trúc phân phối này phải được duy trì:

$$\mathcal{L}_{\text{IRD}} = \frac{1}{M} \sum_{i=1}^M D_{KL}(P_i^{\text{past}} \| P_i^{\text{curr}}) \quad (2.17)$$

trong đó P_{ik}^{past} và P_{ik}^{curr} là các phân phối xác suất (qua Softmax) của độ tương đồng giữa mẫu i và mẫu k dưới mô hình cũ và mô hình hiện tại tương ứng. Vì IRD chỉ quan tâm đến quan hệ tương đồng, không phải nhãn lớp, nó có thể hoạt động hoàn toàn không cần nhãn, đây là điểm quan trọng mà SMC²L kế thừa và phát triển.

Vai trò mở rộng của Buffer

Trong các nghiên cứu trước đó, buffer chỉ được dùng để ôn kiến thức cũ. Co²L mở rộng vai trò của buffer bằng cách đưa các mẫu cũ vào làm các negative trong hàm mất mát tương phản của tác vụ hiện tại. Điều này tạo ra một lực đẩy trực tiếp buộc các lớp dữ liệu mới phải tìm kiếm các vùng trống chưa bị chiếm dụng trên không gian đặc trưng, thay vì ghi đè lên không gian biểu diễn của các lớp cũ. Đây chính là cơ chế Uniformity được phân tích ở Mục 2.3.4: buffer đóng vai trò tăng cường áp lực đẩy, đảm bảo rằng tri thức mới và cũ không xung đột trong không gian biểu diễn.

2.4.2 Ưu nhược điểm của Co²L

Ưu thế so với các baseline

Khi so sánh với iCaRL [16] và DER++ [15], Co²L thể hiện sự ưu việt trong kịch bản Class-Incremental Learning nhờ loại bỏ lớp phân loại trong quá trình huấn luyện backbone. Các phương pháp dựa trên hàm loss phân loại (cross-entropy) thường rất nhạy cảm với sự mất cân bằng dữ liệu giữa tác vụ mới và cũ, dẫn đến thiên kiến (bias) mạnh đối với các lớp mới học. Đây là nguyên nhân chính của hiện tượng Inter-task Confusion đã phân tích ở Mục 2.2.3. Co²L, bằng cách tập trung vào học biểu diễn thay vì ranh giới quyết định, tránh được thiên kiến này và cho phép giai đoạn đánh giá tuyến tính (Linear Probing) phân loại công bằng hơn trên toàn bộ không gian đặc trưng đã tích lũy.

Mặc dù đạt được những kết quả ấn tượng, Co²L còn tồn tại **hai hạn chế cốt lõi** tạo ra khoảng cách giữa lý thuyết và ứng dụng thực tế.

Hạn chế 1 — Phụ thuộc nhãn qua SupCon

Thành phần SupCon trong Co²L yêu cầu nhãn lớp tại mỗi bước huấn luyện để xác định tập dương tính $P(i)$. Điều này tạo ra một mâu thuẫn nội tại: mặc dù IRD không tiêu thụ nhãn, mục tiêu tổng thể của Co²L vẫn phụ thuộc hoàn toàn vào việc có nhãn trong suốt quá trình học biểu diễn.

Trong các ứng dụng thực tế như xe tự lái, drone giám sát hay viễn thám, dữ liệu đến với tốc độ cao và việc gán nhãn thủ công liên tục là không khả thi về cả thời gian lẫn chi phí. Ràng buộc nhãn của SupCon do đó trở thành nút thắt cổ chai nghiêm trọng ngăn cản việc triển khai Co²L trong môi trường không có nhãn.

Hạn chế 2 — IRD áp dụng trên toàn batch gây nhiễu gradient

Trong Co²L, hàm IRD được áp dụng lên *toàn bộ batch*, nghĩa là bao gồm cả các mẫu của tác vụ hiện tại. Tuy nhiên, mô hình cũ (encoder đóng băng từ tác vụ trước) chưa bao giờ thấy dữ liệu tác vụ hiện tại, do đó không có biểu diễn có ý nghĩa cho các mẫu này. Việc tính KL Divergence giữa mô hình hiện tại và mô hình cũ trên dữ liệu mà mô hình cũ chưa biết sẽ đưa vào gradient các tín hiệu nhiễu, thậm chí có thể cản trở quá trình học tác vụ hiện tại thay vì hỗ trợ nó.

Về mặt lý thuyết, đây là hệ quả trực tiếp của việc vi phạm giả định "mô hình cũ có biểu diễn có ý nghĩa cho dữ liệu đầu vào", vốn chỉ đúng với dữ liệu trong buffer. Kết quả thực nghiệm trong Chương 4 xác nhận rằng IRD full-batch thực sự *làm giảm* hiệu suất so với không dùng IRD, từ 75.68% xuống 74.36% trên Seq-CIFAR-10 Class-IL.

2.4.3 Động lực của SMC²L

Đề án đề xuất giảm thiểu 2 hạn chế của Co²L như sau:

Giải quyết Hạn chế 1 — Loại bỏ nhãn và tăng cường biểu diễn tương phản

Đề án ứng dụng SimCLR [2] để xây dựng cặp dương tính hoàn toàn dựa trên tăng cường dữ liệu, không cần nhãn lớp. Nguyên lý cốt lõi đơn giản: hai view được tạo từ cùng một ảnh gốc thông qua các phép biến đổi ngẫu nhiên chính là cặp dương tính tự nhiên, vì chúng chia sẻ cùng nội dung ngữ nghĩa bất kể màu sắc hay vị trí cắt. Việc thay thế SupCon bằng SimCLR loại bỏ hoàn toàn sự phụ thuộc vào nhãn trong giai đoạn học biểu diễn, đồng thời mang lại một lợi thế tiềm ẩn: các đặc trưng không bị ràng buộc bởi ranh giới lớp có xu hướng có tính Task-Agnostic cao hơn, dễ tái sử dụng qua nhiều tác vụ hơn. Tuy nhiên, việc bỏ nhãn cũng đồng nghĩa với mất đi khả năng tận dụng cấu trúc lớp để xây dựng cặp dương tính phong phú như SupCon, cần thiết có một cơ chế để bổ sung bù đắp cho thiếu hụt đó. Đề án đề xuất kỹ thuật LUMP [7] kết hợp với mixup [8] nội suy lỗi giữa mẫu tác vụ hiện tại và mẫu trong buffer:

$$\tilde{x}_i^{mix} = \lambda_{mix} \cdot x_i + (1 - \lambda_{mix}) \cdot x_i^{buf}, \quad \lambda_{mix} \sim \text{Beta}(\alpha, \alpha) \quad (2.18)$$

Phép nội suy này tạo ra các mẫu nằm *giữa* phân phối tác vụ hiện tại và phân phối các tác vụ cũ trong buffer, không cần nhãn, không cần biết mẫu nào cùng lớp. Thay vì dựa vào nhãn để biết "ảnh nào cùng lớp với ảnh nào", LUMP tạo ra cầu nối liên tục qua ranh giới tác vụ ngay ở cấp độ pixel, giúp mục tiêu tương phản không nhãn vẫn nhận được tín hiệu học phong phú từ cả hai phía ranh giới tác vụ. Đây cũng là cơ chế làm mượt sự dịch chuyển biểu diễn đột ngột (feature drift) tại ranh giới tác vụ, một điểm yếu thường gặp của các phương pháp tự giám sát liên tục thuần túy không có cơ chế kết nối với dữ liệu cũ ở cấp đầu vào.

Giải quyết Hạn chế 2 — IRD buffer-only

Thay vì áp dụng IRD trên toàn batch, SMC²L chỉ tính hàm chùng cất quan hệ trên các mẫu trong buffer, tức là các mẫu mà mô hình cũ *đã thấy và có biểu diễn có ý nghĩa*. Điều này loại bỏ nguồn nhiễu gradient từ dữ liệu tác vụ hiện tại, đồng thời cung cấp tín hiệu chùng cất tập trung bảo toàn cấu trúc hình học của tri thức cũ. Kết quả là thành phần IRD có thể thực sự phát huy vai trò bảo toàn ổn định mà không cản trở quá trình học tác vụ mới.

Bảng 2.1 tổng hợp vị trí của các phương pháp liên quan theo bốn tiêu chí cốt lõi. Nhìn vào bức tranh tổng thể, mỗi công trình hiện có chỉ giải quyết được một phần của bài toán: SimCLR loại bỏ hoàn toàn nhãn nhưng không được thiết kế cho luồng dữ liệu liên tục; LUMP có cơ chế làm mượt ranh giới tác vụ nhưng thiếu thành phần bảo toàn tri thức cũ; Co²L kết hợp tương phản với học liên tục nhưng vẫn phụ thuộc nhãn và áp dụng IRD không chọn lọc. Không có phương pháp nào đáp ứng đủ cả bốn tiêu chí trong một pipeline thống nhất. SMC²L được đề xuất nhằm lấp đầy khoảng trống này. Về mặt thiết kế, ba thành phần của SMC²L không hoạt

Bảng 2.1: So sánh các phương pháp liên quan theo các tiêu chí: học tự giám sát (không cần nhãn), học tương phản, hỗ trợ học liên tục đa tác vụ.

Phương pháp	Học tự giám sát	Học tương phản	Học liên tục
Co ² L [4]	×	✓	✓
LUMP [7]	✓	×	✓
SimCLR [2]	✓	✓	×
SMC²L (đề xuất)	✓	✓	✓

động độc lập mà bổ trợ lẫn nhau theo một logic rõ ràng: SimCLR cung cấp mục tiêu học tương phản tự giám sát nền tảng, không tiêu thụ nhãn lớp ở bất kỳ bước nào; LUMP mixup mở rộng vùng học tập qua ranh giới tác vụ ở cấp đầu vào, bù đắp cho việc mất đi tập dương tính phong phú khi không còn dùng SupCon; và IRD buffer-only bảo toàn cấu trúc quan hệ của tri thức cũ một cách tập trung, tránh nhiễu gradient từ dữ liệu tác vụ hiện tại mà mô hình cũ chưa từng thấy. Kết quả là một pipeline học liên tục hoàn toàn tự giám sát, trong đó tính linh hoạt và tính ổn định được cân bằng thông qua hàm mất mát tổng hợp. Chi tiết kiến trúc và từng thành phần của pipeline sẽ được trình bày đầy đủ trong Chương 3.


Chương 3

Phương pháp đề xuất - SMC²L

3.1 Tổng quan kiến trúc

Các luồng dữ liệu để huấn luyện mô hình AI thực tế đến liên tục và không có nhãn, trong khi các phương pháp học liên tục tương phản hiện có như Co²L [4] vẫn phụ thuộc vào đánh nhãn lớp để xây dựng cặp dương tính qua hàm tương phản có giám sát. SMC²L (Self-Supervised Mixup Contrastive Continual Learning) được thiết kế như một pipeline thống nhất trong đó mọi thành phần từng tiêu thụ nhãn đều được thay bằng đối tác không cần nhãn.

Kiến trúc SMC²L được xây dựng trên nền tảng Học liên tục và Học biểu diễn tương phản tự giám sát. Trong đồ án, kiến trúc đề xuất sử dụng Co²L và SimCLR [4, 2] để hiện thực, với cải tiến chính: hàm tương phản có giám sát được thay thành tự giám sát, là sự kết hợp của hàm mất mát SimCLR tương phản ở từng biểu diễn, với LUMP mixup bổ sung một cầu nối ở cấp đầu vào giữa phân phối tác vụ hiện tại và cũ, làm mượt sự dịch chuyển biểu diễn tại ranh giới giữa các tác vụ. Mục tiêu chính của kiến trúc là cho phép mô hình học và tích lũy tri thức một cách liên tục qua nhiều tác vụ khác nhau, đồng thời hạn chế hiện tượng quên thảm khốc mà không cần bất kỳ nhãn lớp nào trong giai đoạn học biểu diễn.



Hình 3.1: Tổng quan kiến trúc. Nhãn bị loại bỏ ở giai đoạn huấn luyện. Mẫu tác vụ hiện tại và mẫu buffer được kết hợp qua LUMP mixup, sau đó tăng cường thành hai view đưa vào encoder hiện tại để tính $\mathcal{L}_{mix}^{con}$. Mẫu buffer được dẫn qua cả encoder hiện tại và encoder đóng băng để tính $\mathcal{L}_{buf}^{IRD}$; sg là stop-gradient trên encoder cũ.

Pipeline tạo ra hai loss bổ sung cho nhau, được tối ưu hóa chung:

$$\mathcal{L} = \mathcal{L}_{mix}^{con} + \lambda \cdot \mathcal{L}_{buf}^{IRD} \quad (3.1)$$

trong đó $\lambda > 0$ cân bằng giữa tính linh hoạt (học qua $\mathcal{L}_{mix}^{con}$) và tính ổn định (bảo toàn qua $\mathcal{L}_{buf}^{IRD}$). Cả hai thành phần hoàn toàn không tiêu thụ nhãn lớp trong giai đoạn học biểu diễn tương phản.

3.2 Xây dựng Batch không nhãn với LUMP Mixup

3.2.1 Loại bỏ chiều nhãn

Trong thiết lập học liên tục có giám sát thông thường, một mini-batch mang các cặp (x_i, y_i) và buffer $\mathcal{M}$ lưu cả nhãn lớp để tính hàm loss phân loại. Trong SMC²L, chiều nhãn bị loại bỏ hoàn toàn ở giai đoạn huấn luyện: cả luồng dữ liệu đến và buffer chỉ lưu ảnh thô. Hậu quả là quản lý buffer rút gọn về lấy mẫu ngẫu nhiên đều theo chỉ số lớp quan sát được, không phụ thuộc vào nhãn ngữ nghĩa cho tính toán loss [14]. Buffer cũng không thể được dùng để mở rộng tập dương tính trong hàm tương phản có giám sát như trong Co²L, điều này đặt ra yêu cầu phải có cơ chế thay thế, đó chính là LUMP mixup.

3.2.2 Nội suy giữa tác vụ hiện tại và buffer

Ở mỗi bước huấn luyện của tác vụ $t > 1$, ta lấy mini-batch N ảnh thô $\{x_i\}_{i=1}^N$ từ luồng tác vụ hiện tại và batch kích thước bằng nhau $\{x_i^{buf}\}_{i=1}^N$ từ buffer $\mathcal{M}$ [15, 14]. Thay vì xử lý song song hai nhóm, ta kết hợp chúng ở cấp độ đầu vào qua nội suy lồi lấy cảm hứng từ LUMP [7] và mixup [8]:

$$\tilde{x}_i^{mix} = \lambda_{mix} \cdot x_i + (1 - \lambda_{mix}) \cdot x_i^{buf} \quad (3.2)$$

với λ_{mix} lấy mẫu một lần cho mỗi mini-batch từ phân phối Beta(α, α) (thực nghiệm $\alpha = 0.1$, phân phối chữ U trên đoạn $[0, 1]$).

Vì không có nhãn, ta **không nội suy vector mục tiêu như trong mixup gốc** [8]. Phép nội suy hoạt động thuần túy trong không gian pixel, tạo ra các mẫu nằm *giữa* phân phối tác vụ hiện tại và phân phối tác vụ cũ. Đây là cơ chế then chốt tạo ra cầu nối liên tục qua ranh giới tác vụ, giúp mục tiêu không nhãn chống lại sự dịch chuyển biểu diễn đột ngột mà các phương pháp tự giám sát liên tục thường gặp phải [7].

3.2.3 Tăng cường hai view và batch làm giàu

Cả ảnh tác vụ hiện tại x_i lẫn ảnh hỗn hợp $\tilde{x}_i^{mix}$ đều được đưa qua cùng pipeline tăng cường hai view $\mathcal{H}$ như trong SimCLR [2]:

$$v_i = h(x_i), v'_i = h'(x_i), mv_i = h(\tilde{x}_i^{mix}), mv'_i = h'(\tilde{x}_i^{mix}) \quad (3.3)$$

với $h, h' \sim \mathcal{H}$ được lấy mẫu độc lập. Bốn view kết quả mỗi mẫu được ghép vào batch làm giàu:

$$\hat{v}_1 = [v_1; mv_1], \quad \hat{v}_2 = [v_2; mv_2] \quad (3.4)$$

để một lần lan truyền tiến qua encoder bao phủ cả tín hiệu tác vụ hiện tại lẫn cầu nối mixup. Từ điểm này, tác vụ liên tục chỉ thấy các view đã tăng cường và không còn phân biệt nguồn gốc của chúng, đảm bảo tính đồng nhất không cần nhãn của toàn pipeline.

3.3 Hàm mất mát tổng hợp của SMC²L

Để giải quyết bài toán tối ưu hóa đa mục tiêu trong học liên tục hoàn toàn không nhãn, SMC²L sử dụng một hàm mất mát tổng hợp. Hàm này là sự kết hợp tuyến tính giữa mục tiêu học tập tri thức mới (qua $\mathcal{L}_{mix}^{con}$) và mục tiêu bảo toàn tri thức cũ (qua $\mathcal{L}_{buf}^{IRD}$):

$$\mathcal{L} = \mathcal{L}_{mix}^{con}(\theta) + \lambda \cdot \mathcal{L}_{buf}^{IRD}(\theta, \theta_{old}) \quad (3.5)$$

Trong đó:

- $\mathcal{L}_{mix}^{con}$: Hàm mất mát tương phản tự giám sát trên batch làm giàu (có cả view mixup), đại diện cho tính **Linh hoạt**. Không cần nhãn lớp.
- $\mathcal{L}_{buf}^{IRD}$: Hàm mất mát chứng cất quan hệ, đại diện cho tính **Ổn định**. Chỉ áp dụng trên mẫu buffer vì encoder cũ không có biểu diễn có ý nghĩa cho dữ liệu tác vụ hiện tại.
- λ (Lambda): Siêu tham số trọng số, quyết định sự đánh đổi giữa hai mục tiêu trên.

Trong mỗi giai đoạn huấn luyện tác vụ, hệ thống thực hiện song song hai quá trình:

- **Quá trình học:** Batch làm giàu (ảnh tác vụ hiện tại + ảnh mixup) được đưa vào để tối ưu hóa hàm mất mát tương phản tự giám sát. Quá trình này thúc đẩy mạng neuron thay đổi trọng số để thích nghi với các đặc trưng mới, đồng thời làm mượt quá trình chuyển tiếp qua mixup.
- **Quá trình ôn:** Chỉ mẫu buffer được sử dụng để tối ưu hóa hàm chứng cất. Quá trình này đóng vai trò như một lực cản, kìm hãm sự thay đổi trọng số quá mức, giữ cho mô hình không quên cấu trúc quan hệ của các đặc trưng cũ.

3.3.1 Hàm mất mát Tương phản

Contrastive Loss dựa trên nguyên lý của InfoNCE (Noise Contrastive Estimation), với mục tiêu là tối đa hóa độ tương đồng giữa hai phiên bản biến thể (views) của cùng một ảnh đầu vào, đồng thời tối thiểu hóa độ tương đồng giữa ảnh đó với tất cả các ảnh khác trong cùng một lô (batch).

Quy trình tính toán được thực hiện qua các bước sau:

- **Bước 1: Chuẩn hóa vector đặc trưng**

Đầu vào là tensor features có kích thước $[2N, D]$, trong đó N là kích thước batch và D là số chiều đặc trưng. Mọi vector đặc trưng $\mathbf{v}_i$ được chuẩn hóa về độ dài đơn vị (L2 normalization) để đảm bảo tính toán độ tương đồng cosine chính xác:

$$\mathbf{z}_i = \frac{\mathbf{v}_i}{\|\mathbf{v}_i\|_2} \quad (3.6)$$

- **Bước 2: Tính ma trận tương đồng**

Hệ thống tính toán độ tương đồng giữa mọi cặp vector trong batch thông qua phép nhân ma trận, sau đó chia cho tham số nhiệt độ τ (temperature):

$$S_{ij} = \frac{\mathbf{z}_i^\top \mathbf{z}_j}{\tau} \quad (3.7)$$

Kết quả là ma trận $S \in \mathbb{R}^{2N \times 2N}$.

- **Bước 3: Loại bỏ tự tương quan và xác định nhãn**

Vì độ tương đồng giữa một ảnh và chính nó (S_{ii}) luôn bằng 1 và không mang thông tin phân biệt, mã nguồn sử dụng mask đường chéo (mask_diag) để loại bỏ các giá trị này. Đồng thời, nhãn mục tiêu được xác định dựa trên vị trí của cặp ảnh dương tính. Với cấu trúc batch ghép $[View_1; View_2]$, cặp dương tính của ảnh tại chỉ số i sẽ nằm tại chỉ số $i + N$ (nếu $i < N$) hoặc $i - N$ (nếu $i \geq N$).

- **Bước 4: Tính toán Loss phân loại**

Các giá trị tương đồng được chia thành hai nhóm: **Positives** - Tập hợp các giá trị $S_{i,j(i)}$ tương ứng với cặp dương tính; và **Negatives** - Tập hợp các giá trị $S_{i,k}$ với $k \neq i$ và $k \neq j(i)$ (các mẫu âm tính).

Hàm mất mát cuối cùng được tính bằng Cross-Entropy, coi đây là bài toán phân loại trong đó mô hình phải tìm ra đúng cặp dương tính trong số các cặp âm tính:

$$\mathcal{L}_{con} = -\frac{1}{2N} \sum_{i=1}^{2N} \log \frac{\exp(S_{i,j(i)})}{\sum_{k \neq i} \exp(S_{i,k})} \quad (3.8)$$

3.3.2 Hàm mất mát Chứng cất quan hệ

Khác với các phương pháp chứng cất truyền thống ép buộc đầu ra logits của mô hình mới phải giống mô hình cũ, hàm mất mát IRD ép buộc **cấu trúc tương quan** giữa các điểm dữ liệu phải được bảo toàn.

Quy trình tính toán gồm các bước:

- **Bước 1: Trích xuất đặc trưng kép**

Một nhóm ảnh từ bộ nhớ đệm được đồng thời đưa qua hai phiên bản của mạng mô hình: phiên bản hiện tại đang được cập nhật trọng số và phiên bản cũ đã được đóng băng để giữ nguyên tham số. Quá trình này tạo ra hai bộ biểu diễn đặc trưng tương ứng $\mathbf{z}^{\text{curr}}$ và $\mathbf{z}^{\text{past}}$, phản ánh cách mỗi mô hình mã hóa thông tin hình ảnh ở hai thời điểm khác nhau trong quá trình học.

- **Bước 2: Xây dựng ma trận tương đồng**

Tương tự như cách tiếp cận của hàm contrastive loss, ta tiến hành xây dựng hai ma trận tương đồng S^{curr} và S^{past} , lần lượt phản ánh mức độ giống nhau giữa các vector đặc trưng do mô hình hiện tại và mô hình quá khứ sinh ra. Trong quá trình này, các phần tử nằm trên đường chéo chính của ma trận được loại bỏ, bởi chúng chỉ biểu diễn sự tự tương đồng của từng mẫu với chính nó. Việc loại bỏ này giúp ta tập trung hoàn toàn vào việc phân tích và khai thác mối quan hệ giữa các mẫu khác nhau trong tập dữ liệu, vốn là yếu tố quan trọng để đánh giá sự ổn định và khả năng duy trì tri thức của mô hình.

- **Bước 3: Chuyển đổi sang phân phối xác suất**

Các giá trị tương đồng được chuyển đổi thành phân phối xác suất bằng hàm Softmax theo chiều hàng (row-wise).

Với mô hình quá khứ (đóng vai trò là đích đến), ta tính xác suất P^{past} :

$$P_{ik}^{\text{past}} = \frac{\exp(S_{ik}^{\text{past}})}{\sum_{j \neq i} \exp(S_{ij}^{\text{past}})} \quad (3.9)$$

Với mô hình hiện tại, ta tính log-xác suất $\log P^{\text{curr}}$ (để phục vụ tính KL Divergence).

- **Bước 4: Tính sai biệt Kullback-Leibler (KL Divergence)**

Hàm mất mát được định nghĩa là độ lệch giữa phân phối quan hệ của mô hình hiện tại so với mô hình quá khứ:

$$\mathcal{L}_{\text{IRD}} = \frac{1}{M} \sum_{i=1}^M D_{KL}(P_i^{\text{past}} \| P_i^{\text{curr}}) = \frac{1}{M} \sum_{i=1}^M \sum_{k \neq i} P_{ik}^{\text{past}} \log \left(\frac{P_{ik}^{\text{past}}}{P_{ik}^{\text{curr}}} \right) \quad (3.10)$$

3.3.3 Siêu tham số λ

- $\lambda = 1$: Giả định rằng tầm quan trọng của việc học tác vụ mới và việc nhớ tác vụ cũ là ngang nhau.
- $\lambda \ll 1$: Mô hình sẽ ưu tiên học mới, dẫn đến hiện tượng **quên thăm khốc**.
- $\lambda \gg 1$: Mô hình bị ràng quá chặt vào quá khứ, dẫn đến việc không thể hội tụ tốt trên dữ liệu mới (**Underfitting**).

Trong thực nghiệm huấn luyện, độ lớn của hai hàm loss này thường nằm trong cùng một khoảng giá trị (1,2). Do đó, việc không cần chuẩn hóa hệ số vẫn đảm bảo rằng vector gradient tổng hợp không bị chi phối hoàn toàn bởi một thành phần đơn lẻ nào, giúp quá trình tối ưu hóa diễn ra ổn định.

Cuối mỗi tác vụ, mô hình hiện tại được snapshot để trở thành giáo viên cho tác vụ tiếp theo, và một phần dữ liệu hiện tại được nạp vào bộ nhớ đệm.

3.4 Kiến trúc triển khai SMC²L


Về mặt triển khai, toàn bộ mã nguồn được tổ chức thành các module độc lập, mỗi module đảm nhiệm một chức năng cụ thể như xử lý dữ liệu, tăng cường dữ liệu, trích xuất đặc trưng, tính toán hàm mất mát tương phản, cũng như quản lý bộ nhớ mẫu từ các tác vụ trước. Cách tổ chức này giúp hệ thống có tính mở rộng cao, dễ dàng điều chỉnh hoặc thay thế từng thành phần để cải tiến mà không ảnh hưởng đến tổng thể kiến trúc.

3.4.1 Khối Tiền xử lý

Trong phương pháp học tương phản, chất lượng của không gian đặc trưng phụ thuộc phần lớn vào chiến lược tăng cường dữ liệu [2]. Lớp ContrastiveTransform trong mã nguồn không chỉ đơn thuần là công cụ làm phong phú dữ liệu, mà nó đóng vai trò là bộ sinh mẫu huấn luyện, quyết định tính bất biến của mô hình.

Chuỗi biến đổi được thiết kế chuyên biệt cho tập dữ liệu tự nhiên kích thước nhỏ như CIFAR-10:

- **Cắt và thay đổi kích thước ngẫu nhiên:** Mã nguồn sử dụng phép biến đổi cắt ngẫu nhiên một vùng ảnh với tỷ lệ diện tích từ 20% đến 100% so với ảnh gốc, sau đó nội suy để đưa về kích thước chuẩn 32×32 . Nó buộc mô hình phải học cách nhận diện vật thể dựa trên các đặc trưng cục bộ và bất biến với tỷ lệ xa gần. Điều này ngăn chặn mô hình ghi nhớ khuôn mẫu tổng thể của bức ảnh.
- **Lật ngang ngẫu nhiên:** Ảnh được lật theo trục dọc với xác suất 50%. Giúp mô hình bất biến với hướng của đối tượng, tăng gấp đôi tính đa dạng của dữ liệu đầu vào mà không làm thay đổi bản chất ngữ nghĩa.




Hình 3.2: Các biến đổi ngẫu nhiên [2].

- **Biến đổi màu sắc và Ảnh xám:** Hệ thống áp dụng thay đổi ngẫu nhiên độ sáng, độ tương phản, độ bão hòa và sắc độ với biên độ 0.4, đồng thời chuyển sang ảnh xám với xác suất 10%. Việc làm méo mó thông tin màu sắc buộc mạng neuron phải tập trung vào hình dáng và kết cấu của vật thể để trích xuất đặc trưng, thay vì dựa dẫm vào biểu đồ màu histogram.
- **Chuẩn hóa dữ liệu:** Bước cuối cùng là chuẩn hóa tensor theo trung bình và độ lệch chuẩn của tập dữ liệu ImageNet. Bước này đưa dữ liệu về phân phối chuẩn tắc, giúp quá trình tối ưu hóa bằng đạo hàm hội tụ nhanh và ổn định hơn.

3.4.2 Khôi Mã hóa

Lớp Encoder là trái tim của hệ thống, chịu trách nhiệm chuyển đổi dữ liệu thị giác thô thành các biểu diễn vector trừu tượng. Kiến trúc này được chia thành hai giai đoạn xử lý riêng biệt: trích xuất đặc trưng và chiếu không gian. Hệ thống sử dụng **backbone ResNet-18** [11] làm bộ trích xuất đặc trưng cơ sở. Tuy nhiên, kiến trúc nguyên bản thiết kế cho ảnh đầu vào 224×224 không phù hợp với ảnh độ phân giải thấp 32×32 của CIFAR-10. Mã nguồn đã thực hiện các sửa đổi cấu trúc quan trọng tại tầng đầu vào:

- **Thay thế lớp tích chập đầu tiên:** Lớp tích chập gốc sử dụng bộ lọc kích thước 7×7 với bước nhảy bằng 2. Điều này làm giảm kích thước không gian của ảnh đi 4 lần ngay lập tức, làm mất mát nghiêm trọng các thông tin chi tiết nhỏ. Mã nguồn thay thế bằng bộ lọc 3×3 với bước nhảy bằng 1. Sự thay đổi này giúp giữ nguyên độ phân giải không gian ban đầu, cho phép mạng học được các đặc trưng hạt mịn ngay từ các lớp nông.
- **Loại bỏ lớp gộp cực đại:** Lớp gộp cực đại đầu tiên cũng bị loại bỏ để tránh việc giảm kích thước đặc trưng xuống quá thấp trước khi đi vào các khối dư. Nếu giữ nguyên, kích thước đặc trưng sẽ chỉ còn 2×2 ở các lớp cuối, không đủ thông tin để phân loại 10 lớp đối tượng phức tạp.



Hình 3.3: Các lớp Resnet-18 [3].

Đầu ra của khối này là một vector đặc trưng h có số chiều là 512, đại diện cho nội dung ngữ nghĩa của bức ảnh. Thay vì sử dụng trực tiếp vector đặc trưng h để tính toán hàm mất mát, hệ thống đưa vector này qua một mạng neuron đa lớp nhỏ, được gọi là **đầu chiều phi tuyến**.

- **Cấu trúc:** Bao gồm một lớp tuyến tính ánh xạ từ 512 qua 512 chiều, đi qua hàm kích hoạt ReLU, và cuối cùng là một lớp tuyến tính ánh xạ xuống 128 chiều.
- **Cơ chế hoạt động:** Khối này hoạt động như một bộ lọc thông tin, loại bỏ các biến thể không cần thiết (như góc xoay, màu nền) để vector z trở nên bất biến tối đa, phục vụ cho việc so khớp trong hàm mất mát tương phản. Sau quá trình huấn luyện, khối này được loại bỏ và chỉ giữ lại backbone cho các tác vụ liên tục.

ResNet nguyên bản được thiết kế cho tập dữ liệu ImageNet với kích thước ảnh đầu vào 224×224 . Tuy nhiên, trong phạm vi đồ án sử dụng dữ liệu CIFAR-10 (32×32), việc áp dụng nguyên trạng kiến trúc gốc sẽ gây ra hiện tượng mất mát thông tin không gian quá sớm. Cụ thể, kiến trúc gốc sử dụng lớp Conv1 kích thước 7×7 với stride 2, theo sau là MaxPool 3×3 với stride 2. Chuỗi thao tác này ngay lập tức giảm kích thước ảnh xuống 4 lần (còn 8×8) ngay khi chưa kịp học được đặc trưng gì.

Để khắc phục, đồ án thực hiện các **tinh chỉnh cho đặc thù tập dữ liệu có độ phân giải thấp** như sau: lớp MaxPool ngay đầu được loại bỏ và lớp Conv1 được thay bằng bộ lọc 3×3 stride 1. Điều chỉnh này đảm bảo duy trì độ phân giải không gian đủ lớn ở các tầng đầu, cho phép mạng học được các đặc trưng tinh tế từ những bức ảnh nhỏ trước khi thực hiện các phép down-sampling ở các tầng sau (Layer 3, Layer 4).

3.4.3 Khôi huấn luyện chính

Lớp Co2LLoss cài đặt cơ chế tối ưu hóa kép, giải quyết đồng thời hai mục tiêu mâu thuẫn trong học liên tục: khả năng học cái mới (thông qua hàm tương phản) và khả năng nhớ cái cũ (thông qua hàm chưng cất), với trọng số λ có thể điều chỉnh.

Lớp ReplayBuffer đóng vai trò là kho lưu trữ ký ức dài hạn cho hệ thống. Trong bối cảnh học liên tục, việc không thể truy cập lại toàn bộ dữ liệu cũ đòi hỏi một cơ chế lưu trữ đại diện hiệu quả [27]. Hệ thống lưu đại diện *buffer_size* ảnh cho mỗi tác vụ, và đem buffer ra học lại chung với tác vụ mới nhất.

Dữ liệu được lưu trữ trên bộ nhớ chính (CPU RAM) thay vì bộ nhớ đồ họa (GPU VRAM). Chỉ khi nào cần sử dụng cho quá trình huấn luyện, một lô dữ liệu nhỏ mới được chuyển sang GPU. Chiến lược này cho phép lưu trữ một lượng lớn mẫu cũ mà không gây tràn bộ nhớ khi huấn luyện các mạng sâu. Quá trình huấn luyện chính là tự giám sát kết hợp lưu buffer bộ nhớ để phục vụ cho các mục đích đánh giá hoặc mở rộng sang các phương pháp có giám sát sau này.

Tại mỗi bước lặp của quá trình huấn luyện, hệ thống rút ngẫu nhiên một lô dữ liệu từ bộ nhớ đệm. Lô dữ liệu này được sử dụng để tính toán hàm mất mát chưng cất. Việc lấy mẫu ngẫu nhiên liên tục này đảm bảo rằng các kiến thức cũ được "ôn tập" lặp đi lặp lại với tần suất ổn định, ngăn cản việc trọng số mạng bị trôi dạt quá xa so với trạng thái tối ưu cũ.

Hàm main là nơi tích hợp tất cả các thành phần trên và các *utils* thành một luồng xử lý hoàn chỉnh chạy từ đầu đến cuối, mô phỏng quá trình học liên tục theo phương pháp học tương phản của hệ thống.

Chương 4

Thực nghiệm

4.1 Thiết lập thực nghiệm

4.1.1 Tập dữ liệu và kịch bản

Theo phân loại của [23], đề tài đánh giá trên ba benchmark dưới hai kịch bản học liên tục:

- **Seq-CIFAR-10** [13]: Chia CIFAR-10 thành 5 tác vụ tuần tự, mỗi tác vụ 2 lớp đối tượng không trùng lặp (Tác vụ 1 học lớp 0–1, Tác vụ 2 học lớp 2–3, ...). Đánh giá dưới Task-IL và Class-IL.
- **Seq-Tiny-ImageNet** [28]: Chia Tiny-ImageNet (200 lớp) thành 10 tác vụ tuần tự, mỗi tác vụ 20 lớp chia tương tự Seq-CIFAR-10. Đánh giá dưới Task-IL và Class-IL.
- **R-MNIST** [20]: Xây dựng 20 tác vụ bằng cách xoay ảnh MNIST với góc lấy mẫu đều trong $[0, \pi)$. Đánh giá dưới Domain-IL.

4.1.2 Kiến trúc mô hình học sâu

Với Seq-CIFAR-10 và Seq-Tiny-ImageNet, sử dụng backbone ResNet-18 [11] được điều chỉnh cho ảnh nhỏ (conv 3×3 , không max-pool), theo sau là đầu chiếu MLP hai lớp ánh xạ xuống không gian 128 chiều với lớp ẩn 512 đơn vị. Với R-MNIST, sử dụng hai lớp tích chập với 20 và 50 bộ lọc (kernel 5×5 , stride 1), mỗi lớp theo sau bởi max-pooling (stride 2), một lớp kết nối đầy đủ 500 đơn vị, và đầu chiếu MLP hai lớp với tất cả chiều ẩn và đầu ra bằng 500.

4.1.3 Tăng cường dữ liệu

Với Seq-CIFAR-10 và Seq-Tiny-ImageNet, áp dụng cắt ngẫu nhiên có thay đổi kích thước, lật ngang ngẫu nhiên, biến đổi màu sắc (cường độ $\{0.4, 0.4, 0.4, 0.1\}$, xác suất 0.8), ảnh xám ngẫu nhiên (xác suất 0.2), và Gaussian blur (xác suất 0.5, chỉ cho Seq-Tiny-ImageNet). Với R-MNIST, áp dụng cắt ngẫu nhiên có thay đổi kích thước (tỷ lệ $[0.7, 1.0]$), nhưng bỏ tăng cường xoay để tránh xung đột với phân chia miền dựa trên góc xoay.

4.1.4 Optimizer và Scheduler

Tất cả mô hình được huấn luyện với Optimizer Adam ($\text{lr}=10^{-3}$, $\text{weight decay}=10^{-4}$, $\epsilon = 10^{-10}$) và Scheduler cosine annealing warm restart [29]. Tác vụ đầu tiên được huấn luyện nhiều epoch hơn các tác vụ sau để thiết lập biểu diễn ban đầu mạnh mẽ. Với giai đoạn đánh giá tuyến tính, huấn luyện bộ phân loại tuyến tính 100 epoch bằng SGD (momentum 0.9). Buffer sử dụng lấy mẫu ngẫu nhiên đều với số lượng bằng nhau mỗi lớp. Tất cả kết quả lấy trung bình trên 5 lần chạy độc lập.

4.1.5 Siêu tham số

Với tất cả thực nghiệm, sử dụng cấu hình mặc định: nhiệt độ $\tau = 0.07$ cho hàm tương phản và $\kappa = 0.07$ cho student, $\kappa^* = 0.07$ cho teacher trong IRD; trọng số IRD $\lambda = 0.6$; hệ số mixup α lấy mẫu từ $\text{Beta}(0.1, 0.1)$; buffer size 500.

Bảng 4.1: Không gian tìm kiếm siêu tham số.

Tham số	Giá trị
Learning rate η	10^{-3}
Weight decay	10^{-4}
Batch size	256
Buffer size	500
τ (tương phản)	$[0.05, 0.2]$
κ (student IRD)	$[0.05, 0.2]$
κ^* (teacher IRD)	$[0.05, 0.2]$
λ (trọng số chứng cất)	$[0.3, 2.0]$
α (mixup Beta)	$[0.1, 0.3]$
Epoch E_0 (tác vụ 1)	$\{100, 500\}$
Epoch E_t (tác vụ $t > 1$)	$\{20, 100\}$
Epoch đánh giá tuyến tính	100

4.2 Quy trình đánh giá

Do đặc thù của học tương phản là không tồn tại lớp Softmax cuối cùng cố định cho các lớp cụ thể ngay từ đầu, mô hình không trực tiếp tối ưu hóa ranh giới quyết định giữa các nhãn theo cách của học giám sát. Thay vào đó, mục tiêu chính của quá trình huấn luyện là học ra một không gian biểu diễn đặc trưng sao cho các mẫu dữ liệu có quan hệ ngữ nghĩa tương đồng được ánh xạ gần nhau, trong khi các mẫu không liên quan bị đẩy ra xa. Chính vì vậy, kỹ thuật "Thăm dò tuyến tính" (Linear Probing) [2] được áp dụng để đánh giá một cách khách quan và nhất quán chất lượng của các đặc trưng đã học được.

- **Cơ chế:** Sau khi hoàn tất quá trình huấn luyện cho toàn bộ chuỗi tác vụ, toàn bộ backbone của mô hình được đóng băng. Trên đầu ra đặc trưng của backbone, một lớp phân loại tuyến tính mới được khởi tạo từ đầu và huấn luyện bằng toàn bộ dữ liệu đã quan sát, trong

khi backbone giữ nguyên. Cách này đảm bảo rằng hiệu năng phân loại thu được chỉ phản ánh trực tiếp không gian đặc trưng đã học.

- **Ý nghĩa:** Nếu backbone học được các biểu diễn tốt và giàu thông tin, các mẫu thuộc cùng một lớp sẽ tự nhiên hình thành các cụm rõ ràng, còn các lớp khác nhau sẽ được phân tách bởi các siêu phẳng tuyến tính đơn giản. Ngược lại, nếu độ chính xác thấp, điều này cho thấy các đặc trưng chưa đủ phân biệt.
- **Tính toán chỉ số:** Dựa trên kết quả dự đoán của lớp phân loại tuyến tính, hệ thống tính toán độ chính xác phân loại trên từng tác vụ và toàn bộ tập test để đánh giá tổng thể. Kết quả được lấy trung bình trên 5 lần chạy độc lập.

4.3 Kết quả thực nghiệm

4.3.1 Kết quả chính

Bảng 4.2 so sánh SMC²L với các baseline học liên tục dựa trên hồi tưởng trên ba benchmark với buffer size 500. Phương pháp đề xuất liên tục vượt trội hoặc ngang bằng Co²L trên tất cả kịch bản trong khi hoạt động hoàn toàn tự giám sát, không truy cập nhãn lớp nào trong giai đoạn học biểu diễn.

Bảng 4.2: Độ chính xác phân loại (%) trên Seq-CIFAR-10, Seq-Tiny-ImageNet và R-MNIST với buffer size 500. Kết quả của các phương pháp lấy từ [4]. Kết quả tốt nhất in **đậm**. Kết quả SMC²L lấy trung bình trên 5 lần chạy độc lập.

Tập dữ liệu Phương pháp	Seq-CIFAR-10		Seq-Tiny-ImageNet		R-MNIST
	Class-IL	Task-IL	Class-IL	Task-IL	Domain-IL
ER [14]	57.74±0.27	93.61±0.27	9.99±0.29	48.64±0.46	94.89±0.95
GEM [20]	26.20±1.26	92.16±0.64	-	-	92.55±0.85
A-GEM [21]	22.67±0.57	89.48±1.45	8.06±0.04	25.33±0.49	89.04±7.01
iCaRL [16]	47.55±3.95	88.22±2.62	9.38±1.53	31.55±3.27	-
FDR [19]	28.71±3.23	93.29±0.59	10.54±0.21	49.88±0.71	95.48±0.68
GSS [30]	49.73±4.78	91.02±1.57	-	-	89.38±3.12
HAL [31]	41.79±4.46	84.54±2.36	-	-	92.35±0.81
DER [15]	70.51±1.67	93.40±0.39	17.75±1.14	51.78±0.88	97.57±1.47
DER++ [15]	72.70±1.36	93.88±0.50	19.38±1.41	51.91±0.68	97.54±0.43
Co ² L [4]	74.26±0.77	95.90±0.26	20.12±0.42	53.04±0.69	98.65±0.31
SMC²L (đề xuất)	76.17±0.25	93.97±0.18	38.56±0.18	67.89±0.37	98.53±0.11

Trên **Seq-CIFAR-10**, SMC²L đạt **76.17%** độ chính xác Class-IL, vượt Co²L gần 2% và tất cả baseline khác. Trên **Seq-Tiny-ImageNet**, quan sát xu hướng tương tự với con số **38.56%** trên độ chính xác Class-IL, vượt Co²L gần **18%**, cho thấy khả năng mở rộng tốt lên các dataset phức tạp hơn với nhiều lớp hơn và đặc trưng khó phân biệt hơn. Trên **R-MNIST** dưới Domain-IL, phương pháp đạt **98.53%**, chứng minh khả năng chuyển giao biểu diễn xuyên miền mạnh mẽ.

Hai ưu điểm chính được thể hiện qua kết quả nhất quán so với Co²L: (1) thay hàm tương phản có giám sát bằng mục tiêu tự giám sát SimCLR loại bỏ sự phụ thuộc vào nhãn lớp, đồng thời học đặc trưng tổng quát hơn không bị ràng buộc bởi ranh giới lớp; (2) tăng cường LUMP mixup làm mượt ranh giới biểu diễn giữa phân phối tác vụ hiện tại và cũ ở cấp đầu vào, bổ sung cho cơ chế IRD bảo toàn cấu trúc quan hệ.

4.3.2 Thực nghiệm trên tập dữ liệu ảnh vệ tinh

Để xác nhận tính hiệu quả của SMC²L trong bối cảnh thực tiễn của đề tài, đồ án thực nghiệm trên tập dữ liệu EuroSAT [32] - một tập dữ liệu ảnh vệ tinh Sentinel-2 gồm 10 lớp phân loại sử dụng đất (rừng, đường cao tốc, khu dân cư, đồng ruộng...) với tổng cộng 27.000 ảnh. Theo giao thức Class-IL, EuroSAT được chia thành 5 tác vụ tuần tự, mỗi tác vụ gồm 2 lớp không trùng lặp, với buffer size 500 và thiết lập siêu tham số giống hệt các thực nghiệm trên Seq-CIFAR-10.

Bảng 4.3: Kết quả trên EuroSAT, buffer size 500. Đơn vị: %.

Phương pháp	Class-IL	Task-IL
SMC ² L	92.70 $\pm$ 0.28	99.44 $\pm$ 0.18

SMC²L đạt **92.70%** (± 0.28) Class-IL trên EuroSAT, cho thấy framework tự giám sát hoạt động hiệu quả trên ảnh viễn thám - bối cảnh thực tiễn trực tiếp của đề tài.

Hai điểm đáng chú ý trong kết quả này. Thứ nhất, pixel-space mixup giữa các task trên ảnh vệ tinh có thể tạo ra các mẫu trung gian phức tạp về mặt ngữ nghĩa (ví dụ nội suy giữa ảnh rừng và ảnh đường cao tốc). Tuy nhiên mục tiêu contrastive không yêu cầu mẫu mix phải có ý nghĩa ngữ nghĩa - nó chỉ cần hai augmented views của cùng nguồn ảnh có biểu diễn nhất quán. LUMP do đó vẫn tạo được cầu nối liên tục qua ranh giới tác vụ mà không bị ảnh hưởng bởi đặc thù của ảnh viễn thám. Thứ hai, toàn bộ giai đoạn học biểu diễn không tiêu thụ nhãn nào, điều này đặc biệt phù hợp với bối cảnh drone và viễn thám, nơi dữ liệu đến liên tục và việc gán nhãn thủ công là không khả thi. Trong triển khai thực tế, nhãn có thể được thay thế bằng cơ chế gán pseudo-label dựa trên cấu trúc cluster của không gian biểu diễn, kết hợp với một lượng nhỏ ảnh có nhãn thật để mapping.

4.4 Nghiên cứu Ablation

Để xác minh đóng góp của từng thành phần, ba biến thể được so sánh trên Seq-CIFAR-10 dưới Class-IL: (a) không có LUMP và không có IRD (chỉ dùng SimCLR thuần), (b) có LUMP nhưng không có IRD, (c) có IRD nhưng không có LUMP, và (d) phương pháp đầy đủ. Bảng 4.4 cho thấy mỗi thành phần đóng góp tích cực, và sự kết hợp đạt hiệu suất tốt nhất.

Ta tiếp tục so sánh việc áp dụng IRD chỉ trên mẫu buffer (thiết kế của SMC²L) so với toàn batch (như trong Co²L). Kết quả trong Bảng 4.4 cho thấy IRD trên toàn batch (74.36%)

thậm chí thấp hơn biến thể không có IRD (75.68%). Điều này xác nhận rằng encoder cũ không có biểu diễn có ý nghĩa cho dữ liệu tác vụ hiện tại, chứng cứ trên các mẫu đó đưa vào gradient nhiều thay vì tín hiệu hữu ích. Hạn chế chứng cứ chỉ trên mẫu buffer giải quyết vấn đề này và tạo ra tín hiệu chứng cứ sạch hơn.

Bảng 4.4: Nghiên cứu ablation các kết quả accuracy tốt nhất trên Seq-CIFAR-10, buffer size 500. Đơn vị: %.

Biến thể	Class-IL	Task-IL
Không LUMP, không IRD (SimCLR thuần)	74.13	93.15
Có LUMP, không IRD	75.68	93.56
Không LUMP, có IRD (buffer-only)	75.01	93.87
IRD trên toàn batch (như Co ² L)	74.36	93.88
SMC²L đầy đủ (LUMP + IRD buffer-only)	76.75	94.62

Nhận xét tổng hợp từ ablation:

- **Cả LUMP lẫn IRD buffer-only đều cần thiết:** Biến thể SimCLR thuần (74.13%) thấp hơn đề xuất đầy đủ 2.62% Class-IL. Học tương phản thuần túy mà không có cơ chế bảo toàn sẽ bị quên, dù không cần nhãn.
- **IRD buffer-only tốt hơn IRD full-batch:** Biến thể IRD toàn batch (74.36%) thấp hơn không có IRD (75.68%), xác nhận rằng chứng cứ trên dữ liệu tác vụ hiện tại với mô hình cũ gây hại hơn là có lợi.
- **LUMP mixup có đóng góp lớn trong Class-IL:** "Có LUMP, không IRD" (75.68%) có kết quả tốt hơn "Không LUMP, có IRD" (75.01%) trong Class-IL, cho thấy mixup đặc biệt hiệu quả trong học biểu diễn tương phản.
- **Hai thành phần bổ trợ nhau:** Kết hợp cả hai đạt 76.75%, cao hơn từng thành phần riêng lẻ, chứng minh tính bổ trợ (complementarity) của LUMP mixup và IRD buffer-only.

Chương 5

Tổng kết

5.1 Đánh giá thực nghiệm

Qua quá trình nghiên cứu lý thuyết, thiết kế và thực nghiệm khung SMC²L trên ba benchmark chuẩn của học liên tục Seq-CIFAR-10, Seq-Tiny-ImageNet và R-MNIST, đề tài đã đạt được những kết quả quan trọng.

5.1.1 Về hiệu quả tổng thể

SMC²L liên tục vượt trội hoặc ngang bằng Co²L trên tất cả kịch bản trong khi hoạt động *hoàn toàn không cần nhãn* trong giai đoạn học biểu diễn. Mức tăng đáng kể nhất trên Seq-Tiny-ImageNet Class-IL (+18% so với Co²L) cho thấy phương pháp mở rộng tốt hơn lên các tập dữ liệu phức tạp hơn. Trên R-MNIST, phương pháp đạt 98.53% Domain-IL, sánh ngang Co²L. So với các phương pháp hồi tưởng truyền thống (ER, GEM, iCaRL) vốn sử dụng nhãn, SMC²L vượt trội rõ rệt trong kịch bản Class-IL, kịch bản khó và thực tế nhất.

Đề tài đã chứng minh sự cộng hưởng hiệu quả giữa ba thành phần cốt lõi:

- **SimCLR không nhãn:** Thay thế hàm tương phản có giám sát mà không làm giảm chất lượng biểu diễn, thậm chí còn cải thiện trong nhiều kịch bản nhờ việc học đặc trưng tổng quát hơn không bị ràng buộc bởi ranh giới lớp. Đây là lợi thế tự nhiên của tự giám sát: khi không bị "lệch" theo nhãn cụ thể, mô hình học cấu trúc ngữ nghĩa bền vững hơn.
- **LUMP Mixup:** Tạo cầu nối mượt mà giữa phân phối tác vụ hiện tại và cũ ở cấp độ đầu vào pixel, giúp không gian biểu diễn không bị dịch chuyển đột ngột tại ranh giới tác vụ. Kết quả ablation xác nhận LUMP đặc biệt quan trọng trong Class-IL.
- **IRD buffer-only:** Bảo toàn cấu trúc hình học của biểu diễn cũ mà không đưa vào nhiễu từ dữ liệu tác vụ hiện tại chưa được mô hình cũ thấy. Đây là sự khác biệt quan trọng so với Co²L, được xác nhận qua ablation: IRD full-batch thậm chí còn giảm hiệu suất.

5.1.2 Về hạn chế

- **Task-IL thấp hơn Co²L:** Trên Seq-CIFAR-10 Task-IL (93.97% so với 95.90%), phương pháp tự giám sát thua khi Task ID được cung cấp. Điều này hợp lý vì không có nhãn đồng nghĩa với không tận dụng được thông tin lớp.
- **Chi phí tính toán:** Việc tính hai lần lan truyền tiến (encoder hiện tại và encoder cũ trên mẫu buffer), cộng với xử lý batch làm giàu 2 view mỗi mẫu, làm tăng chi phí tính toán so với học giám sát thông thường.
- **Lấy mẫu buffer ngẫu nhiên:** Chiến lược lấy mẫu đều chưa tối ưu về mặt lựa chọn mẫu đại diện. Việc vô tình loại bỏ các mẫu khó có thể ảnh hưởng đến khả năng khôi phục kiến thức cũ.

5.2 Hướng phát triển

Qua quá trình phát triển và hoàn thiện đề tài qua hai giai đoạn, từ thực nghiệm sơ khởi đến khung SMC²L hoàn chỉnh, chúng tôi nhận thấy một số hạn chế như đã phân tích ở trên. Nếu đề tài được tiếp tục nghiên cứu, các hướng phát triển sau đây được xem là có tiềm năng cải thiện đáng kể hiệu suất và khả năng ứng dụng thực tế của hệ thống.

5.2.1 Cải tiến chiến lược lấy mẫu Buffer

Chiến lược lấy mẫu ngẫu nhiên theo tác vụ hiện tại đơn giản và hiệu quả về mặt tính toán, nhưng không đảm bảo rằng các mẫu được lưu lại là đại diện tốt nhất cho phân phối của tác vụ cũ. Trong thực tế, một số mẫu mang nhiều thông tin phân biệt hơn các mẫu khác, và việc lấy mẫu ngẫu nhiên có thể vô tình bỏ qua những mẫu quan trọng đó, ảnh hưởng trực tiếp đến chất lượng cả LUMP mixup lẫn tín hiệu chứng cứ IRD. Hai hướng thay thế tiềm năng bao gồm:

- **Herdning:** Thay vì lấy mẫu ngẫu nhiên, hệ thống chủ động chọn các mẫu gần tâm cụm nhất trong không gian đặc trưng, tức những mẫu đại diện nhất cho phân phối trung bình của tác vụ đó. Chiến lược này đảm bảo buffer luôn chứa các mẫu có tính đại diện cao, giúp IRD buffer-only bảo toàn cấu trúc hình học của tri thức cũ chính xác hơn, đồng thời cung cấp các điểm neo (anchor) ổn định hơn cho LUMP mixup tại ranh giới tác vụ.
- **Lựa chọn dựa trên gradient (Gradient-based):** Ưu tiên các mẫu có gradient đa dạng nhất trong không gian tham số, tương tự nguyên lý của GSS [30] nhưng được điều chỉnh để hoạt động hoàn toàn không cần nhãn, phù hợp với thiết kế tự giám sát của SMC²L. Những mẫu có gradient khác biệt lớn với nhau sẽ cung cấp tín hiệu học đa chiều hơn, tránh tình trạng buffer chứa nhiều mẫu thừa, tương tự nhau và không bổ sung thêm thông tin mới cho quá trình ôn tập.

5.2.2 Siêu tham số động trong quá trình huấn luyện

Giá trị λ cố định trong hàm mất mát tổng hợp $\mathcal{L} = \mathcal{L}_{mix}^{con} + \lambda \cdot \mathcal{L}_{buf}^{IRD}$ hiện tại chưa phản ánh được thực tế rằng nhu cầu bảo toàn tri thức thay đổi theo từng giai đoạn của chuỗi tác vụ. Ở các tác vụ đầu, khi lượng tri thức tích lũy còn ít, mô hình cần tính linh hoạt cao hơn để học nhanh; ở các tác vụ sau, khi tri thức cũ ngày càng phong phú và quý giá, nhu cầu bảo toàn tăng lên đáng kể.

Một hướng cải tiến tự nhiên là điều chỉnh λ động dựa trên chỉ số độ quên đo được sau mỗi tác vụ. Cụ thể, nếu F_T vượt quá một ngưỡng cho trước, tức mô hình đang quên nhiều hơn mức cho phép, λ được tăng lên tự động để tăng cường tín hiệu chương cất IRD. Ngược lại, nếu F_T thấp, λ có thể giảm để nhường không gian tối ưu hóa cho việc học tác vụ mới. Cơ chế phản hồi này biến λ từ một siêu tham số tĩnh thành một bộ điều khiển thích nghi, tự động cân bằng giữa tính linh hoạt và tính ổn định dựa trên tín hiệu thực nghiệm từ chính quá trình huấn luyện, thay vì phụ thuộc vào việc tinh chỉnh thủ công trước khi chạy thực nghiệm.

5.3 Kết luận

Đề tài đã ứng dụng học tương phản tự giám sát vào học liên tục. Đề tài giai đoạn 1 đã xây dựng một khung học liên tục tự giám sát hoàn toàn không cần nhãn, đến giai đoạn 2 đã cải thiện và cạnh tranh được với các phương pháp có giám sát mạnh trong kịch bản học tăng cường lớp.

SMC²L là một giải pháp thực tế cho các hệ thống mà việc gán nhãn dữ liệu liên tục là không khả thi. SMC²L không chỉ nhằm khắc phục các hạn chế hiện tại mà còn hướng tới việc xây dựng các hệ thống AI thực sự thông minh, linh hoạt và bền vững, tiến tới việc loại bỏ bước gán nhãn trong quá trình huấn luyện mô hình AI.

Tài liệu tham khảo

- [1] L. Wang, X. Zhang, H. Su, and J. Zhu, “A comprehensive survey of continual learning: Theory, method and application,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 46, no. 8, pp. 5362–5383, 2024.
- [2] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A simple framework for contrastive learning of visual representations,” in *Proceedings of the International Conference on Machine Learning*, pp. 1597–1607, PMLR, 2020.
- [3] S.-M. WadhaAl-Khater, “Using 3d-vgg-16 and 3d-resnet-18 deep learning models and fabemd techniques in the detection of malware,” 2024.
- [4] H. Cha, J. Lee, and J. Shin, “Co2l: Contrastive continual learning,” in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 9516–9525, 2021.
- [5] M. McCloskey and N. J. Cohen, “Catastrophic interference in connectionist networks: The sequential learning problem,” *Psychology of Learning and Motivation*, vol. 24, pp. 109–165, 1989.
- [6] I. J. Goodfellow, M. Mirza, D. Xiao, A. Courville, and Y. Bengio, “An empirical investigation of catastrophic forgetting in gradient-based neural networks,” *arXiv preprint arXiv:1312.6211*, 2013.
- [7] D. Madaan, J. Yoon, Y. Li, Y. Liu, and S. J. Hwang, “Representational continuity for unsupervised continual learning,” in *International Conference on Learning Representations*, 2022.
- [8] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, “Mixup: Beyond empirical risk minimization,” in *International Conference on Learning Representations*, 2018.
- [9] D. G. Lowe, “Distinctive image features from scale-invariant keypoints,” *International Journal of Computer Vision*, vol. 60, no. 2, pp. 91–110, 2004.
- [10] N. Dalal and B. Triggs, “Histograms of oriented gradients for human detection,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 886–893, 2005.

- [11] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016.
- [12] S. Ioffe and C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in *Proceedings of the International Conference on Machine Learning*, pp. 448–456, 2015.
- [13] A. Krizhevsky and G. Hinton, “Learning multiple layers of features from tiny images,” tech. rep., University of Toronto, 2009.
- [14] M. Riemer, I. Cases, R. Ajemian, M. Liu, I. Rish, Y. Tu, and G. Tesauro, “Learning to learn without forgetting by maximizing transfer and minimizing interference,” in *International Conference on Learning Representations*, 2019.
- [15] P. Buzzega, M. Boschini, A. Porrello, D. Abati, and S. Calderara, “Dark experience for general continual learning: a strong, simple baseline,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 15920–15930, 2020.
- [16] S.-A. Rebuffi, A. Kolesnikov, G. Sperl, and C. H. Lampert, “icarl: Incremental classifier and representation learning,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 2001–2010, 2017.
- [17] J. Kirkpatrick, R. Pascanu, N. C. Rabinowitz, J. Veness, G. Desjardins, A. A. Rusu, K. Milan, J. Quan, T. Ramalho, A. Grabska-Barwinska, D. Hassabis, C. Clopath, D. Kumaran, and R. Hadsell, “Overcoming catastrophic forgetting in neural networks,” *Proceedings of the National Academy of Sciences*, vol. 114, pp. 3521–3526, 2017.
- [18] J. Serra, D. Suris, M. Miron, and A. Karatzoglou, “Overcoming catastrophic forgetting with hard attention to the task,” in *Proceedings of the International Conference on Machine Learning*, pp. 4548–4557, 2018.
- [19] A. S. Benjamin, D. Rolnick, and K. P. Kording, “Measuring and regularizing networks in function space,” in *International Conference on Learning Representations*, 2019.
- [20] D. Lopez-Paz and M. Ranzato, “Gradient episodic memory for continual learning,” in *Advances in Neural Information Processing Systems*, pp. 6470–6479, 2017.
- [21] A. Chaudhry, M. Ranzato, M. Rohrbach, and M. Elhoseiny, “Efficient lifelong learning with A-GEM,” in *International Conference on Learning Representations*, 2019.
- [22] A. Mallya and S. Lazebnik, “PackNet: Adding multiple tasks to a single network by iterative pruning,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 7765–7773, 2018.

- [23] G. M. van de Ven and A. S. Tolias, “Three scenarios for continual learning,” in *NeurIPS Continual Learning Workshop*, 2019.
- [24] T. Wang and P. Isola, “Understanding contrastive representation learning through alignment and uniformity on the hypersphere,” *Proceedings of the International Conference on Machine Learning*, 2020.
- [25] P. Khosla, Y. Tian, C. Wang, A. Sarna, P. Isola, A. Maschinot, C. Liu, and D. Krishnan, “Supervised contrastive learning,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 18661–18673, 2020.
- [26] Z. Fang, J. Wang, L. Wang, L. Zhang, Y. Yang, and Z. Liu, “SEED: Self-supervised distillation for visual representation,” in *International Conference on Learning Representations*, 2021.
- [27] A. Robins, “Catastrophic forgetting, rehearsal and pseudorehearsal,” *Connection Science*, vol. 7, no. 2, pp. 123–146, 1995.
- [28] S. CS231N, “Tiny ImageNet visual recognition challenge,” 2015.
- [29] I. Loshchilov and F. Hutter, “SGDR: Stochastic gradient descent with warm restarts,” in *International Conference on Learning Representations*, 2017.
- [30] R. Aljundi, M. Lin, B. Goujaud, and Y. Bengio, “Gradient based sample selection for online continual learning,” in *Advances in Neural Information Processing Systems*, 2019.
- [31] A. Chaudhry, A. Gordo, P. K. Dokania, P. H. S. Torr, and D. Lopez-Paz, “Using hindsight to anchor past knowledge in continual learning,” in *AAAI Conference on Artificial Intelligence*, 2021.
- [32] P. Helber, B. Bischke, A. Dengel, and D. Borth, “Eurosat: A novel dataset and deep learning benchmark for land use and land cover classification,” *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 12, no. 7, pp. 2217–2226, 2019.